

Экономический атлас муниципалитетов: типы потребления по безналичным тратам 2023–2024

Методологический отчёт. Конкурс СберИндекса, трек «Кластеризация». Версия от 30.09.2026.

Все числа в отчёте взяты из файлов проекта: `reports/DATA.md`, `data/processed/build_summary.json`, `outputs/baseline_icvi.csv`, `outputs/network_ablation.csv`, `outputs/baseline_best_k.json`, `outputs/jury/jury_meta.json`, `outputs/diagnostics.json`, `outputs/indices.csv`, `outputs/method_ranking.csv`, `outputs/compare_stability.csv`, `outputs/compare_meta.json`, `outputs/final_choice.md`, `outputs/types.csv`, `outputs/interpret/`, `outputs/dynamics/`.

0. Коротко

2 016 МО с полными рядами за 2023–2024 годы делятся на **7 типов местного потребления**. Типологию даёт KEFRiN Шалилеха и Миркина: k-means на признаках МО вместе со строками графа «чи траты движутся вместе».

Восемь методов сравниваются по шести индексам в восьми вариантах рейтинга при $K = 7$: пороговое агрегирование Алескерова и Борда, с AVU и без, на сквозных признаках и по медиане месяцев. KEFRiN — единственный метод, который во всех восьми вариантах стоит на 1-м или 2-м месте, и самый устойчивый по месяцам: при одном правиле выравнивания меток МО проводит в модальном типе 77 % месяцев, у CANUS 73 %, у Ward 59 %. Первая она не везде: с AVU на сквозных первым идёт Ward (его место держится на одном z_{AVU}), по медиане месяцев — k-means (п. 6.4).

Типы (`outputs/types.csv`): 0 — сельские районы с самыми низкими тратами; 1 — районы и малые города с малой долей транспорта и здоровья; 2 — сельские районы с самой высокой долей маркетплейсов; 3 — Москва, Подмосковье и соседние областные центры; 4 — Север и Восток: высокие траты при худшей доступности рынков; 5 — Петербург и крупные города; 6 — районы Сибири с высокой долей транспорта.

Если считать сменой только тип, который держится от трёх месяцев, 76 % МО за два года тип не меняли. Направленный сдвиг один: 45 МО центральных областей перешли за год из типа 1 в тип 2 (раздел 7).

Росстат в кластеризацию не входил, а типы по нему различаются сильно: зарплата ($\eta_H^2 = 0,55$), население (0,44), занятые в торговле (0,33) и в сельском хозяйстве (0,24). Доля общепита в тратах меняется от 1,8 % до 6,5 %, а доля занятых в общепите почти одинакова ($\eta_H^2 = 0,017$): малый бизнес Росстат не видит.

Индекс мобильности СберИндекса есть только у 297 МО Северо-Запада, поэтому в признаки он не вошёл. На пересечении с типологией (274 МО) типы по нему тоже различаются ($\eta_H^2 = 0,68$, п. 8.6).

Путь от данных к типам:

траты МО по месяцам → признаки МО → сеть МО → восемь методов кластеризации → шесть индексов качества против случайного разбиения → итоговая типология → переходы МО между типами → описание типов.

Шаг	Что делаем	Где в коде
Данные	2 016 МО × 24 месяца × 6 категорий трат	<code>scripts/download_data.py</code> , <code>scripts/build_panel.py</code>
Признаки	доли категорий, уровень трат, тренды, доступность рынков	<code>src/features.py</code>
Сеть	пять видов рёбер, kNN против порога	<code>src/network.py</code>
Методы	k-means, Ward, GMM, Leiden, спектральная, KEFRiN, CANUS, паттерны Алескерова–Мячина	<code>src/baseline.py</code> , <code>src/jury_methods.py</code>
Индексы	SW, CH, S_Dbw, AVI, AVU, MQ и z против перестановок	<code>src/icvi.py</code>

1. Данные

1.1 Источники

Источник	Что берём	Лицензия
Набор хакатона СберИндекса (<code>hackathonlicence.zip</code>)	<code>consumption.parquet</code> : средние безналичные траты жителя МО за месяц, руб., по модели СберИндекса, пять категорий и итор; <code>market_access.parquet</code> : индекс доступности рынков за 2024 год; <code>connection.parquet</code> : расстояния между МО по дорогам (3 303 736 пар) и по железной дороге (2 638 628 пар) для 2 574 МО	CC BY-SA 4.0

Источник	Что берём	Лицензия
Справочник МО и границ СберИндекса (xlsx + gpkg)	<code>territory_id</code> , версии ОКТМО, тип МО, регион, центр, полигоны	CC BY-SA 4.0
Росстат, БДМО, из каталога «Если быть точным»	население на 1 января; среднесписочная численность работников и среднемесячная зарплата по разделам ОКВЭД2 без малого предпринимательства; 2021–2024	CC BY 4.0
API СберИндекса, sberindex.ru	индекс мобильности (<code>indeks-mobilnosti</code>): одно годовое значение в км на МО за 2024 и 2025 годы, только Северо-Запад; служит внешней проверкой (п. 1.5, 8.6)	в выгрузке не указана

У всех 14 скачанных файлов есть контрольные суммы SHA-256 (`data/raw/SHA256SUMS`). Файлы Росстата лежат внутри zip-архивов на 1,3–3,7 ГБ; скрипт читает оглавление архива и нужные записи по HTTP Range, весь архив не качает.

1.2 Единица наблюдения и период

Единица — МО верхнего уровня в постоянных границах, то есть `territory_id` СберИндекса. Смена имени, типа или ОКТМО (например, район стал муниципальным округом) ряд не рвёт: у 413 МО панели несколько версий в справочнике, и все они уже сведены в один `territory_id`. Новый идентификатор появляется только при объединении или разделении МО.

- Период: январь 2023 – декабрь 2024, 24 месяца без пропусков в общей сетке.
- Панель: 2 190 МО, 353 647 строк.
- Основа кластеризации — **2 016 МО со всеми 24 месяцами** из 73 регионов (в панели 77). Среди них 980 муниципальных районов, 433 городских округа, 361 муниципальный округ и 242 внутригородские территории Москвы, Петербурга и Севастополя.

1.3 Категории

Пять исходных категорий: продовольствие, маркетплейсы, транспорт, здоровье, общественное питание, и итог «Все категории». Сумма пяти составляет от 45% до 90% итога, в среднем 72%, и ни разу его не превышает. Остаток мы выделили в шестую категорию «Прочее» = итог – сумма пяти; её доля от 9,5% до 54,9%, отрицательных значений нет.

Медианные доли: продовольствие 44,7%, прочее 28,2%, маркетплейсы 13,5%, транспорт 5,7%, здоровье 4,9%, общепит 2,6%.

1.4 Что исключено и почему

1. **174 МО с неполными рядами** (от 1 до 23 месяцев; например, у 56 МО ровно 12 месяцев). СберИндекс показывает МО только в те месяцы, когда оценка проходит порог качества. Пропуски не заполняли: восстановленное значение было бы нашей моделью поверх модели СберИндекса. На карте эти МО показаны серым.
2. **Пять МО с изменением границ** входят в эти 174. В Московской области городские округа Павловский Посад и Электрогорск объединились в Павлово-Посадский городской округ, в Рязанской области город Сасово вошёл в Сасовский муниципальный округ. У предшественников есть 12 месяцев 2023 года, у преемников 10 месяцев 2024-го. Ряды не склеивали: средние траты на жителя двух МО нельзя сложить без весов населения.
3. **Отраслевая структура Росстата взята за 2023 год**. За 2024 год работники и зарплата есть только у 2 396 территорий, за 2023-й — у 2 578–2 579. Доли занятости по разделам ОКВЭД2 Росстат часто скрывает (раздел В пуст у 84% МО). Нулями пропуски не заменяли.

1.5 Ограничения данных

- **Индекс мобильности СберИндекса скачан, но в кластеризацию не входит**. Выгрузка API (`data/raw/api/indeks-mobilnosti.parquet`) — 594 строки: по одному значению в км за 2024 и 2025 годы для 297 МО, и все они в Северо-Западном федеральном округе. С нашими 2 016 МО пересекаются 274, это 14 %. Кода МО в выгрузке нет, поэтому название сопоставляем со справочником внутри регионов округа; одно название (территория Петербурга) в справочнике не нашлось. Признак, который есть у 14 % МО и в одном округе, для типологии страны не годится: пропуски пришлось бы заполнять моделью. Поэтому индекс служит внешней проверкой типов на пересечении (п. 8.6, `scripts/check_mobility.py`). Слой сети по потокам людей тоже нет: в выгрузке только значение для МО, без пар «откуда — куда».
- `value` — модельная оценка по безналичным операциям. Наличные и траты вне Сбера в неё не входят, поэтому в МО с малой долей безнала уровень занижен. Уровень трат мы читаем как «покупательная способность × доля безнала», а не как доход.
- 24 месяца: сезонность видна, длинного тренда нет.
- Росстат считает зарплату и работников без малого предпринимательства; в сельских районах это заметная часть занятости.

- Население за 2024 год отсутствует у 27 МО сбалансированной части (26 из них — вся Рязанская область), за 2023 год — у 34 МО панели (32 — Кемеровская область). Причину второго пропуска мы не нашли: строки у Росстата есть, но привязка по году не работала.
- Индекса доступности рынков нет у 12 МО сбалансированной части: это северные территории без круглогодичной дороги (Якутия, Таймыр, Камчатка, Чукотка).

2. Признаки

Набор	Признаки	Число
Помесячный (МО × месяц)	6 долей категорий в итоге (сумма 1); ln трат на жителя; индекс доступности рынков	8
Сквозной (одна строка на МО)	средние за 24 месяца для 6 долей и ln уровня; годовые тренды тех же 7 величин (наклон МНК по времени в единицах «за год»); индекс доступности рынков	15

Что несёт каждая группа:

- **доли** описывают, на что тратят, и не зависят от уровня дохода;
- **уровень** (ln трат на жителя) показывает, сколько тратят;
- **тренды** показывают, куда движется МО за два года, например как быстро растёт доля маркетплейсов;
- **доступность рынков** описывает экономическую географию: сколько рынков сбыта и покупок достижимо из МО. У 12 северных МО без круглогодичной дороги её нет, и мы ставим минимум по стране: нет дороги — худшая доступность.

Нормировка. Каждый признак переводим в z-оценку по МО: ежемесячные внутри своего месяца (так уходит общая для страны сезонность), сквозные по всей выборке. Затем обрезаем до $\pm 4\sigma$, чтобы единичные выбросы вроде Чукотки или центра Москвы не перетягивали на себя центры кластеров. После этого у всех признаков одинаковый вес.

Почему нет ежемесячного темпа роста. Прирост $\Delta \ln$ трат к прошлому месяцу мы считали, но в ежемесячную кластеризацию не взяли: его ранговая корреляция между соседними месяцами около $-0,25$. Отрицательная связь соседних месяцев означает шум вокруг уровня: всплеск одного месяца откатывается в следующем. Такой признак перебрасывал бы МО между типами без экономической причины. Движение МО входит в сквозные признаки через годовые тренды.

Росстат в признаки не входит сознательно. Зарплату, занятость по ОКВЭД2 и население мы оставили для внешней проверки типов (раздел 8). Если бы они были в признаках, фраза «типы различаются по зарплате» следовала бы из построения, а не была бы находкой.

3. Сеть

3.1 Пять видов рёбер

Узел — МО (2 016). Для каждого вида рёбер строим матрицу сходства $N \times N$, из неё — граф.

Рёбро	Что сравнивает	Как считаем
Косинус долей	структуру трат	косинус векторов z-оценок долей 6 категорий. z-оценка нужна потому, что сырые доли у всех МО похожи и косинус почти везде близок к 1. Помесячно — вектор месяца, для сквозного периода — $6 \times 24 = 144$ значения подряд
Корреляция рядов с лагом	совместное движение трат во времени	ряды ln трат на жителя по пяти категориям и итогу; из каждого месяца вычтено среднее по всем МО, так что общая сезонность не создаёт ложных связей. Корреляция при сдвигах 0, ± 1 , ± 2 месяца, среднее по категориям, затем максимум по сдвигу. Сдвиг сохраняем: «МО j повторяет МО i с опозданием на L месяцев»
DTW	форму рядов с допуском на сдвиг	динамическое выравнивание рядов итоговых трат (z по времени) с полосой Сако–Чибы [28] в 3 месяца; сходство $\exp(-D / \text{med } D)$. Для всех пар это дорого, поэтому считаем на случайной подвыборке 500 МО
Транспортная близость	географию	$\exp(-d/\sigma)$, где d — расстояние по дорогам из набора хакатона; где дороги нет — по железной дороге; где нет и её — по прямой между центрами $\times 1,3$. σ — медиана расстояния до 15-го соседа, 146 км
Траты × близость	похожесть трат у соседей	$\max(\cos, 0) \cdot \exp(-d/\sigma)$: МО связаны, если они похожи по структуре трат и лежат недалеко друг от друга

Из матрицы граф получается двумя способами:

- **kNN**: каждому МО 15 самых похожих соседей, затем симметризация $w_{ij} = \max(w_{ij}, w_{ji})$;
- **порог**: оставляем 1,1% самых сильных пар. Порог подобран так, чтобы средняя степень (около 22) совпала с kNN и сравнение было честным.

3.2 Сравнение графов

Все графы построены на сквозном периоде (`outputs/network_ablation.csv`). Жаккар считается по множествам рёбер.

Граф	Рёбер	Ср. степень	Изолятов	Компонент	Жаккар с косинусным kNN	Leiden при $\gamma=1$: сообществ	Модулярность Q
косинус, kNN	22 594	22,4	0	1	1	11	0,72
косинус, порог	22 343	22,2	1 493	1 539	0,087	1 543	0,19
корреляция с лагом, kNN	25 496	25,3	0	1	0,070	9	0,67
корреляция с лагом, порог	22 343	22,2	1 537	1 547	0,064	1 550	0,25
близость, kNN	18 781	18,6	0	1	0,063	23	0,87
траты × близость, kNN	19 376	19,2	0	1	0,095	18	0,85
траты × близость, порог	22 343	22,2	392	561	0,074	569	0,50
DTW, kNN (500 МО)	5 533	22,1	0	1	— (с корреляцией на тех же 500 МО: 0,17)	6	0,60

Вторая таблица: Leiden с $K = 10$ на каждом kNN-графе и разбиение k-means ($K = 7$, сети не видит), оценённое на том же графе.

Граф	Leiden: SW	Leiden: CH	Leiden: AVI	Leiden: Q	ARI Leiden и k-means	k-means на этом графе: Q	его z против перестановок
косинус	0,032	168	0,82	0,72	0,21	0,40	164
корреляция с лагом	0,009	146	0,77	0,67	0,23	0,43	197
близость	−0,007	85	0,98	0,81	0,14	0,31	98
траты × близость	0,026	125	0,99	0,81	0,18	0,42	119

Что из этого следует.

- Порог не годится.** При той же средней степени пороговый граф оставляет без единого ребра 74–76% МО на косинусе и корреляции (1 493 и 1 537 из 2 016) и 19% на комбинированном. Сильные сходства собираются в плотные ядра типичных МО, а нетипичные не набирают ни одной пары выше порога. Leiden на таком графе выдаёт по сообществу на каждый изолят. kNN гарантирует каждому МО соседей, поэтому дальше используем только kNN.
- Разные рёбра — разные сети.** Жаккар рёбер любого графа с косинусным kNN лежит в пределах 0,06–0,10, у DTW с корреляцией на одной подвыборке — 0,17. Это не шумные копии одной сети: выбор ребра меняет ответ, и его приходится обосновывать.
- У транспортной сети самая высокая модулярность:** 0,87 и 23 сообщества при $\gamma=1$. География даёт самую чёткую сетевую структуру, но её сообщества — это территории, а не типы экономики: силуэт сообществ в пространстве признаков около нуля (−0,007), CH самый низкий (85). Такой граф отвечает на вопрос «где», а атлас спрашивает «какой».
- Типы трат сгруппированы в пространстве.** Разбиение k-means, построенное без сети, на чисто транспортном графе даёт $Q = 0,31$ и $z = 98$ против случайной перестановки меток. Похожие по структуре трат МО лежат рядом гораздо чаще, чем при случайном размещении. Это содержательный результат для раздела 8, а для методики — довод, что граф «траты × близость» соединяет две связанные вещи.
- Косинусный граф и признаки построены из одних и тех же долей.** Топология здесь не независима от атрибутов, и для методов сети с атрибутами (KEFRiN, CANUS) такая сеть мало добавляет к признакам. Лаборатория СберИндекса в статье об индексах для сетей с атрибутами проверяла их на генераторах, где атрибуты отвязаны от топологии [15]. Корреляционный и транспортный графы несут то, чего в долях нет.

3.3 Какой граф основной

Основной граф — корреляция рядов с лагом, kNN (`lagcorr_knn`): $k = 15$, симметризация `max`, ряды `ln` трат на жителя по пяти категориям и итогу за вычетом среднего по стране в каждом месяце, лаг до 2 месяцев. Граф один на весь период: 25 496 рёбер, средняя степень 25,3, изолятов нет, одна компонента (`outputs/diagnostics.json`). На нём работают Leiden, спектральная кластеризация, KEFRiN и CANUS, на нём же считаются AVI, AVU и Q для всех восьми методов.

Почему он:

- **связный и без изолятов**, в отличие от пороговых графов (п. 1);

- **несёт новую информацию:** Жаккар его рёбер с косинусным kNN 0,070. Граф отвечает на вопрос «чи траты движутся вместе», а не повторяет структуру трат, из которой собраны признаки;
- **при этом согласуется с признаками:** разбиение k-means, построенное только по признакам, на нём модулярнее, чем на любом другом kNN-графе: $Q = 0,43$ и $z = 197$ (косинус 0,40 и 164, «траты × близость» 0,42 и 119, близость 0,31 и 98). Атрибуты и топология согласны, но не дублируют друг друга. Это и есть условие, при котором методам «сеть + атрибуты» есть что добавить;
- **не подменяет тип регионом:** на близости и «траты × близость» Leiden при $K = 10$ даёт AVI 0,98–0,99, то есть почти изолированные куски карты (п. 3).

От косинусного kNN отказались, хотя в базовом прогоне основным стоял он (`configs/baseline.yaml`) и он ближе к подходу лаборатории в «Profiling Consumption» [16]: KEFRiN и CANUS получили бы одни и те же доли дважды, как в их первом прогоне (п. 4.10). DTW посчитан только на подвыборке 500 МО, и его рёбра совпадают с корреляционными на 0,17 по Жаккару.

Оговорка: граф один на 24 месяца, поэтому Leiden, который видит только граф, даёт одно разбиение на все месяцы. Его устойчивость 1,0 в разделе 6 получается по построению.

4. Методы

Восемь методов: пять базовых и три из работ членов жюри. Базовые видят что-то одно: k-means, Ward и GMM — признаки, Leiden и спектральная кластеризация — сеть. KEFRiN и CANUS видят и то и другое, паттерн-кластеризация смотрит только на порядок показателей. Все признаковые методы получают одни и те же признаки (раздел 2), все сетевые — один граф `lagcorr_knn` (п. 3.3).

4.1 k-means [7, 8]. Минимизирует сумму квадратов расстояний МО до центра своего кластера в пространстве признаков. Сети не видит. `sklearn`, 20 запусков из разных стартовых центров (k-means++), seed 42. Это точка отсчёта; индекс CN построен на той же геометрии и ему подыгрывает (раздел 5).

4.2 Ward [32]. Агломеративная кластеризация: начинаем с одиночных МО и на каждом шаге сливаем два кластера, у которых меньше всего растёт внутрикластерная сумма квадратов, $\Delta = \frac{n_a n_b}{n_a + n_b} \|c_a - c_b\|^2$. Критерий тот же, что у k-means, но поиск жадный и без случайного старта, поэтому результат детерминирован; дерево режем на K кластеров. Сети не видит. `sklearn.cluster.AgglomerativeClustering`, евклидово расстояние, те же признаки, что у k-means.

4.3 GMM [33]. Смесь K гауссиан, подобранная ЕМ-алгоритмом; МО относится к компоненте с наибольшей апостериорной вероятностью. В отличие от k-means, у каждого кластера свой разброс по каждому признаку. Ковариация **диагональная**, а не полная. Шесть долей трат в сумме дают 1, поэтому ковариация признаков вырождена: наименьшее собственное число ковариационной матрицы сквозных признаков равно 0. Полная ковариация держится только на регуляризации (`reg_covar`) и на сквозных признаках при $K = 7$ выделяет компоненты из 15 и 26 МО вдоль этого вырожденного направления. Диагональная даёт кластеры от 216 до 463 МО и втрое меньше параметров: $K \cdot 2d$ против $K \cdot (d + d(d + 1)/2)$, при $K = 12$ и 15 признаках 360 против 1 620 на 2 016 МО. `sklearn.mixture.GaussianMixture`, 5 запусков, seed 42. Сети не видит.

4.4 Leiden [9, 10]. Делит сеть на сообщества, максимизируя модулярность с разрешением γ (функционал Райхардта–Борнхольдта): чем больше γ , тем мельче сообщества. Признаков не видит. Чтобы сравнивать методы при одном K , γ подбираем бисекцией по $\log \gamma$ на отрезке $[0,001; 20]$ (30 шагов, до пяти сидов); если ровно K не выходит, берём ближайшее. $\gamma = 1$ даёт «естественное» разбиение по чистой модулярности.

4.5 Спектральная кластеризация [34, 35]. Нормализованный вариант Ши–Малика на том же графе `lagcorr_knn` с весами рёбер: K собственных векторов лапласиана случайного блуждания $L_{rw} = I - D^{-1}A$ с наименьшими собственными числами дают каждому МО K координат, по ним работает k-means (10 запусков, seed 42). Это непрерывная релаксация нормированного разреза: минимизируется доля веса рёбер, уходящих из кластера. Признаков не видит, K задаётся напрямую. Граф один на весь период, поэтому, как у Leiden, разбиение одно на все месяцы. `sklearn.cluster.SpectralClustering(affinity="precomputed")`.

4.6 KEFRiN [11]. k-means для сети с атрибутами в подходе «восстановления данных» Миркина [13]. У каждого кластера два центра: центр признаков c_k и «сетевой центр» λ_k — типичная строка матрицы связей. МО относят к кластеру, где меньше $\rho d(y_i, c_k) + \xi d(p_i, \lambda_k)$, где p_i — строка матрицы связей МО i . По сути это k-means на склейке признаков и строк смежности. Берём версию KEFRiNc с косинусным расстоянием, $\rho = \xi = 1$, 10 запусков, признаки в z-оценках.

4.7 CANUS [12]. Те же два центра на кластер, но центры обновляются градиентным спуском, и в шаге участвуют только МО, у которых норма градиента лежит в полосе $[\mu - \tau\sigma, \mu + \tau\sigma]$. Полосу оценивают бутстрэпом после первого назначения. Фильтр отсекает МО, которые слишком сильно тянут центр на себя; у нас это нетипичные малые МО. 300 эпох, шаг 0,001, $\tau = 1$, $\rho = \zeta = 1$, старт k-means++, правило `vanilla_filtered`.

4.8 Порядково-инвариантная паттерн-кластеризация Алескерова–Мячина [17, 18]. Каждую долю категории переводим в ранг-процентиль по всей панели (все МО × все месяцы), так что паттерн читается как «в чём МО сильнее относительно страны». Паттерн МО — знаки попарных сравнений его показателей; для пяти категорий это 10 пар. Кластер — все МО с одинаковым паттерном. Метрики нет, число кластеров не задаётся, результат не меняется при любом монотонном преобразовании показателей. Второй вариант сравнивает только соседние оси, то есть форму ломаной в параллельных координатах.

4.9 Чужой код и что в нём изменено

Метод	Откуда	Коммит	Лицензия	Как используем
KEFRiN	Sorooshi/KEFRiN	f9f96b1	файла LICENSE нет (в README указана MIT)	не копируем: <code>scripts/fetch_external.py</code> клонирует в <code>external/</code> на этом коммите, <code>src/jury_methods.py</code> импортирует
CANUS	Sorooshi/CANUS	754622a	файла LICENSE нет	так же; своя только одна функция (ниже)
Паттерны	открытого кода не нашли	—	наша	<code>pattern_codes</code> , <code>pattern_clusters</code> в <code>src/jury_methods.py</code>

Единственное изменение — быстрая норма градиентов в CANUS. В `canus.py` норма градиента по каждому узлу считается циклом `autograd`: N вызовов на эпоху, 0,9–1,3 с на эпоху, 2–3 часа на весь прогон. Для косинусного расстояния $d = 1 - \cos(v, c)$ та же норма выражается формулой

$$\left\| \frac{\partial d}{\partial c} \right\| = \frac{\|\hat{v} - \cos(v, c) \hat{c}\|}{\|c\|}, \quad \hat{v} = \frac{v}{\|v\|}, \quad \hat{c} = \frac{c}{\|c\|},$$

и считается для всех узлов сразу, примерно в 20 раз быстрее. Мы подменяем одну функцию (`_fast_grad_norms`), остальной алгоритм автора не тронут. Проверка совпадения: нормы равны результату `autograd` с точностью $1e-4$ (тест `test_canus_fast_grad_norms_match_autograd`), метки на пробных запусках (январь 2023 — 5 эпох, июнь 2023 — 10 эпох, 2 016 узлов) совпали с исходным кодом на 100%. Подмена выключается параметром `fast_grad_norms: false` в `configs/jury.yaml1`.

4.10 Первый прогон методов жюри (30.09)

Прогон шёл на временных признаках и графе: пять долей в z-оценках и косинусный kNN с $k = 10$. В сравнении (раздел 6) все методы получают общие признаки и граф.

- KEFRiN и CANUS при $K = 8$: все восемь кластеров непусты в каждом месяце; самый малый кластер — 115 МО у KEFRiN и 96 у CANUS. 25 запусков (24 месяца и сквозной) в разных прогонах заняли 291–369 с у KEFRiN и 223–496 с у CANUS: время зависит от того, чем ещё занята машина (последний прогон — `outputs/jury/jury_meta.json`).
- Паттерны полного порядка: 127 разных паттернов на всей панели (предел $5! = 120$, ещё 7 дали случайные равенства процентилей), в месяце медиана 108. Для типологии это слишком мелко. Паттерны формы ломаной: 17, восемь самых частых покрывают 85% МО-месяцев.
- **Как паттерны приведены к общему K** (`merge_patterns` в `src/compare.py`). 127 исходных паттернов остаются описательным результатом (`outputs/jury/pattern_dictionary.csv`). Для сравнения их сливаем агломеративно. На каждом шаге сливаются два кластера, чьи паттерны отличаются меньше всего попарных сравнений; у строгих порядков это одна перестановка соседних категорий. Из таких пар берём ту, что теряет меньше всего R^2 в пространстве ранг-процентилей долей, то есть с наименьшим приращением Уорда $\frac{n_a n_b}{n_a + n_b} \|c_a - c_b\|^2$. Слияние одно на все МО-месяцы, так что номер слитого кластера в каждом месяце один и тот же. При $K = 7$ в кластерах 14, 23, 11, 23, 23, 18 и 15 исходных паттернов. Самый массовый (13 016 МО-месяцев) — «маркетплейсы и продукты впереди, общепит и транспорт в хвосте», сельский профиль. Второй (10 057) — «общепит, транспорт и здоровье выше продуктов», городской.
- В сравнении раздела 6 KEFRiN и CANUS запущены заново на общих признаках и графе `lagcorr_knn`.

5. Индексы качества

5.1 Формулы

Обозначения: N — число МО, $C_1, \dots, C_K$ — кластеры, x_i — вектор признаков МО, c_k — центр кластера, $\bar{x}$ — общий центр, A — симметричная матрица весов сети без петель, $m = \frac{1}{2} \sum_{ij} A_{ij}$. Для графовых индексов $S_{ab} = \sum_{i \in C_a} \sum_{j \in C_b} A_{ij}$ — вес связей между кластерами (внутренние рёбра в S_{aa} входят дважды), $\text{tot}_a = \sum_b S_{ab}$, $\text{out}_a = \text{tot}_a - S_{aa}$.

Силуэт SW [1]. $a(i)$ — среднее расстояние до своего кластера, $b(i)$ — наименьшее среднее расстояние до чужого: $s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$, $SW = \frac{1}{N} \sum_i s(i)$. Больше — лучше; у одноэлементного кластера $s(i) = 0$.

Калински–Харабаш CH [2]. $CH = \frac{\text{tr}(B)/(K-1)}{\text{tr}(W)/(N-K)}$, $\text{tr}(B) = \sum_k |C_k| \|c_k - \bar{x}\|^2$, $\text{tr}(W) = \sum_k \sum_{i \in C_k} \|x_i - c_k\|^2$. Больше — лучше.

Индекс растёт на сферических кластерах одного размера и поэтому подыгрывает k-means.

S_Dbw [3]. Разброс внутри кластеров плюс плотность между ними: $\text{Scat} = \frac{1}{K} \sum_k \frac{\|\sigma(C_k)\|}{\|\sigma(X)\|}$, $\text{stdev} = \frac{1}{K} \sqrt{\sum_k \|\sigma(C_k)\|^2}$, $\text{Dens_bw} = \frac{1}{K(K-1)} \sum_k \sum_{l \neq k} \frac{\text{density}(u_{kl})}{\max\{\text{density}(c_k), \text{density}(c_l)\}}$, $u_{kl} = \frac{1}{2}(c_k + c_l)$, где $\text{density}(u)$ — число точек $C_k \cup C_l$ в шаре радиуса stdev вокруг u , а $\sigma(\cdot)$ — вектор дисперсий по признакам. $S_Dbw = \text{Scat} + \text{Dens_bw}$, меньше — лучше. Берём вариант статьи; вариант пакета `s-dbw` (σ — вектор СКО, плотность центра по своему кластеру) тоже реализован и совпадает с пакетом.

AVI, средняя изолированность [4]. $I_a = S_{aa}/\text{tot}_a$ — доля веса связей кластера, которая остаётся внутри него; $AVI = \frac{1}{K} \sum_a I_a$. Больше — лучше. У случайного разбиения $I_a \approx |C_a|/N$ и $AVI \approx 1/K$.

AVU, средняя «слитость» [4]. $U_{ab} = \frac{S_{ab}}{\text{out}_a + \text{out}_b - S_{ab}}$ — доля общих связей пары среди всех их внешних связей; $AVU = \frac{1}{K} \sum_a \sum_{b \neq a} U_{ab}$. Меньше — лучше. Деление на K , а не на $K(K-1)$ — как в открытом коде лаборатории жюри (библиотека `Pattern`).

ANUI [4] (в критериях нет, даём для справки): $ANUI = \frac{1}{AVU + 1/AVI}$, больше — лучше. В коде лаборатории это графовый индекс по умолчанию.

MQ = модулярность Q [5]: $Q = \sum_a \left[\frac{S_{aa}}{2m} - \left(\frac{\text{tot}_a}{2m} \right)^2 \right]$. Больше — лучше; у случайного разбиения $Q \approx 0$. Почему MQ понимаем как Q — в п. 5.5.

5.2 На чём считаются

Индекс	Пространство	Лучше	Что даёт случайное разбиение
SW	признаки, евклидово расстояние	больше	≈ 0
CH	признаки	больше	мало
S_Dbw	признаки	меньше	—
AVI	граф	больше	$\approx 1/K$
AVU	граф	меньше	$\approx (K-1)/(2K-3)$, см. п. 5.4
MQ (Q)	граф	больше	≈ 0

Признаковые индексы считаются на признаках того же периода (8 помесечных или 15 сквозных), графовые — на одном и том же графе. Правило одно для всех методов: у Leiden тоже есть SW и CH, хотя признаков он не видит, а у k-means тоже есть AVI и Q, хотя он не видит сети. Поэтому таблица «метод × индекс» заполнена целиком.

5.3 Сравнение со случайной перестановкой

Сырые AVI и AVU при разных K несравнимы: первый у случайного разбиения падает как $1/K$, второй — как $(K-1)/(2K-3)$. Поэтому каждое разбиение сравниваем с его же метками, случайно перемешанными по МО (размеры кластеров те же): 200 перестановок на сквозном периоде и 20 на каждом месяце. Для каждого индекса

$$z = \frac{I - \text{mean}_{\text{перест}}(I)}{\text{sd}_{\text{перест}}(I)}.$$

У индексов «больше — лучше» хорошее разбиение даёт большой положительный z , у S_Dbw — отрицательный.

Пример на сквозном периоде при $K = 7$ из базового прогона, где графовые индексы считались на косинусном kNN (`outputs/baseline_icvi.csv`); те же индексы на основном графе — в разделе 6:

	SW	CH	S_Dbw	AVI	AVU	Q
k-means	0,147 ($z = 32$)	340	0,58 ($z = -80$)	0,54 ($z = 168$)	0,547 ($z = +18,7$)	0,40 ($z = 164$)
Leiden	0,044 ($z = 13$)	217	0,66 ($z = -59$)	0,86 ($z = 294$)	0,574 ($z = +42,8$)	0,71 ($z = 275$)

Каждый метод выигрывает на своём поле: k-means — на признаковых индексах, Leiden — на графовых. Поэтому методы нельзя сравнивать по одному индексу, и нужна свёртка шести ранжировок (раздел 6). Для AVI случайная база при $K = 7$ равна $1/7 \approx 0,14$: оба разбиения далеко от неё.

Проверки реализации (`tests/test_icvi.py`): SW и CH совпадают со `sklearn` до $1e-10$, в том числе с одноэлементным кластером и метками с пропусками; S_Dbw в варианте пакета совпадает с `s-dbw`; Q совпадает с `networkx` до $1e-12$. Отдельно, вне тестов, AVI, AVU, ANUI и Q сверены с кодом `Pattern` на пяти случайных графах: расхождение меньше $1e-9$. Сторож направления: на

графе из изолированных клик $AVI = 1$, $AVU = 0$, $Q = 1 - 1/K$; на случайном разбиении $AVI \approx 1/K$, $Q \approx 0$; у правильного разбиения z имеет верный знак по всем шести индексам.

5.4 Свойства AVU

AVU — единственный из шести индексов, где на наших данных z у хороших разбиений положителен: у k-means при $K = 7$ он равен +18,7, у Leiden +42,8, и так при любом K от 4 до 12. Мы разобрались, откуда это берётся. Ниже три свойства формулы в том виде, в каком её считает библиотека Pattern, на неориентированном графе.

В U_{ab} и числитель, и знаменатель состоят только из весов разреза: S_{aa} в формулу не входит.

(а) При $K \leq 3$ индекс вырожден. При $K = 2$ имеем $S_{12} = out_1 = out_2$, откуда $U_{12} = U_{21} = 1$ и $AVU = 1$ у любого разбиения. При $K = 3$ знаменатель $out_a + out_b - S_{ab}$ равен всему весу разреза W , так что $\sum_{a \neq b} U_{ab} = 2W/W = 2$ и $AVU = 2/3$ у любого разбиения. Тест `test_avu_degenerate` проверяет это на случайном графе.

(б) AVU не видит, какая доля веса осталась внутри кластеров. Если все внутренние веса умножить на любое число, AVU не изменится. Разбиение, у которого 99% связей внутри кластеров, и разбиение, у которого внутри 10%, получают одинаковый AVU, если вес разреза распределён по парам кластеров одинаково. Тест `test_avu_cut_shape`: четыре кластера по 50 узлов, вероятность ребра внутри 0,5 и между 0,05; у правильного разбиения AVI больше 0,7, у случайного меньше, а AVU у обоих около 3/5.

(в) У случайного разбиения $AVU \approx (K-1)/(2K-3)$. При равных размерах $S_{ab} \approx s$ для всех пар, $out_a \approx (K-1)s$, $U_{ab} \approx 1/(2K-3)$. Отсюда 0,60 при $K = 4$, 0,55 при $K = 7$ и 0,53 при $K = 10$. AVU выше этой базы, когда разрез кластера сосредоточен на одном-двух соседях (в пределе пара кластеров, связанных только друг с другом, даёт $U_{ab} = 1$), и ниже, когда разрез ровно размазан по всем парам или есть кластер-«хаб».

Что это значит для наших данных. Типы потребления лежат на непрерывной шкале: от крупного города через малые города к сельским районам. Соседи МО в сети попадают в соседние типы, и разрез сосредоточен на парах соседних типов. Поэтому у хороших разбиений AVU на уровне случайной базы или выше: у k-means при $K = 7$ 0,547 против 0,545 у базы, у Leiden 0,574. Положительный z_{AVU} здесь — свойство формулы на данных с упорядоченными типами, а не ошибка расчёта и не признак плохого разбиения. На транспортном графе, где типы трат перемешаны по территории, z_{AVU} того же разбиения k-means отрицателен (-43,6).

Как мы учитываем AVU:

1. Диапазон K у всех методов начинается с 4 (свойство «а»).
2. AVU даём рядом с его случайной базой и z . В выборе K и в рейтинге методов z_{AVU} входит со знаком «меньше — лучше», как требуют критерии, но всегда вместе с AVI, который несёт внутренний вес. Их сочетание, ANUI, — графовый индекс лаборатории по умолчанию; мы приводим его для справки. На основном графе `lagcorr_knn` при $K = 7$ z_{AVU} на сквозных признаках тоже положителен у всех восьми методов: от +2,1 у Ward до +23,0 у KEFRiN (`outputs/indices.csv`). **Что меняется без AVU** (`outputs/method_ranking.csv`, пять индексов вместо шести):
 - лидер порогового рейтинга при $K = 7$ меняется: на сквозных с Ward на KEFRiN, по медиане месяцев с k-means на KEFRiN и CANUS (вровень);
 - лидер Борда меняется: на сквозных с k-means на KEFRiN, по медиане месяцев KEFRiN догоняет k-means и делит с ним первое место;
 - лучшее K по Борда на сквозных у KEFRiN (10), CANUS (9), Ward (7), GMM, спектральной и паттернов (4) то же, у k-means $8 \rightarrow 5$, у Leiden $4 \rightarrow 7$.

Итог: от AVU зависит, кто первый в варианте рейтинга, но не итоговый выбор. KEFRiN на 1-м или 2-м месте и с AVU, и без (п. 6.4), а без AVU первая во всех четырёх вариантах. У KEFRiN на сквозных единственная тройка — как раз по z_{AVU} , а первое место Ward на сквозных держится на одной единице по z_{AVU} .

3. Для обсуждения с авторами предлагаем вариант, где в знаменатель входит весь вес кластеров: $U_{ab}^* = \frac{S_{ab}}{tot_a + tot_b - S_{ab}}$ — коэффициент Жаккара по всем рёбрам, касающимся a или b . Он обращается в 0 на изолированных кластерах и различает случаи из свойства «б». В таблицы он не входит и индекс из критериев не заменяет.

Оговорка. Полный текст первоисточника [4] и статьи лаборатории [15] нам недоступен, поэтому формулу и нормировку мы взяли из открытого кода лаборатории. Если в оригинале AVU определён иначе, свойства «а»–«в» относятся к версии Pattern; деление на K или на $K(K-1)$ меняет только константы, но не сами свойства.

5.5 Какой MQ

MQ — модулярность Ньюмана–Гирвана Q [5]. Так ответили организаторы конкурса на наш вопрос письмом 30.09: «MQ — Modularity Quality или просто Modularity (модулярность)». Её мы и считаем; в коде лаборатории жюри графовая метрика называется так же, `modularity`.¹

¹ «Modularization Quality» Манкоридиса [6] на неориентированном графе дублировал бы AVI: вклад кластера $CF_a = \frac{2\mu_a}{2\mu_a + \sum_{b \neq a} (\epsilon_{ab} + \epsilon_{ba})}$ при однократном учёте рёбер разреза равен $S_{aa}/(S_{aa} + \text{out}_a) = I_a$, откуда $MQ = K \cdot AVI$.

6. Сравнение методов

6.1 Восемь методов × шесть индексов при $K = 7$

Граф `lagcorr_knn`, признаки раздела 2 (`outputs/indices.csv`, `variant = common`). Помесячные индексы — медиана по 24 месяцам. Лучшее значение в блоке выделено.

Метод	Период	SW ↑	CH ↑	S_Dbw ↓	AVI ↑	AVU ↓	MQ ↑	z_{AVI}	z_{AVU}	z_{MQ}
k-means	сквозные	0,147	339,9	0,578	0,526	0,545	0,425	181	9,6	197
Leiden	сквозные	0,037	202,0	0,601	0,842	0,539	0,676	289	14,2	269
Ward	сквозные	0,103	285,8	0,595	0,535	0,498	0,428	185	2,1	193
GMM	сквозные	0,069	259,6	0,660	0,517	0,545	0,384	174	8,7	175
спектральная	сквозные	0,045	207,3	0,633	0,840	0,509	0,662	292	10,6	259
KEFRIN	сквозные	0,105	301,5	0,568	0,637	0,567	0,505	222	23,0	229
CANUS	сквозные	0,117	286,7	0,626	0,547	0,568	0,447	186	22,5	201
паттерны, слияние	сквозные	0,064	196,9	0,760	0,368	0,528	0,302	118	13,6	145
k-means	медиана месяцев	0,195	647,8	0,446	0,490	0,509	0,358	155	−10,6	170
Leiden	медиана месяцев	0,032	280,6	0,696	0,842	0,539	0,676	260	12,7	239
Ward	медиана месяцев	0,145	546,8	0,533	0,475	0,505	0,346	158	−1,5	165
GMM	медиана месяцев	0,147	540,4	0,625	0,500	0,523	0,340	170	1,7	167
спектральная	медиана месяцев	0,043	301,4	0,641	0,840	0,509	0,662	293	10,2	237
KEFRIN	медиана месяцев	0,150	531,3	0,518	0,545	0,549	0,442	194	11,1	209
CANUS	медиана месяцев	0,158	489,6	0,526	0,469	0,557	0,371	168	17,0	190
паттерны, слияние	медиана месяцев	0,088	355,9	0,745	0,358	0,458	0,293	98	10,6	116

Каждый метод выигрывает на своём поле: k-means — SW и CH, которые меряют ровно то, что он оптимизирует; Leiden и спектральная — AVI и Q, то есть граф (z_{AVI} 289 и 292 на сквозных). Ward и GMM, как и k-means, видят только признаки, но по SW и CH ему уступают. Методы «сеть + атрибуты» лежат между признаковыми и графовыми. Сырой AVU у лучших по графу разбиений не ниже, чем у случайного, отсюда положительный z_{AVU} (п. 5.4); ближе всех к случайной базе Ward ($z_{AVU} = 2,1$ на сквозных).

6.2 Рейтинг: пороговое агрегирование и Борда

Индексы для сведения — SW, CH, S_Dbw, z_{AVI} , z_{AVU} , Q (AVI и AVU через z : их сырые значения зависят от K). Оценки 1/2/3 и места — `outputs/method_ranking.csv`. При восьми методах оценка 1 — места 1–2 по индексу, оценка 2 — места 3–5, оценка 3 — места 6–8.

Места при $K = 7$ во всех восьми вариантах рейтинга (П — пороговое агрегирование, Б — Борда):

Метод	сквозные: П	П без AVU	Б	Б без AVU	медиана месяцев: П	П без AVU	Б	Б без AVU	худшее место
KEFRIN	2	1	2	1	2	1	2	1	2
k-means	4	4	1	2	1	3	1	1	4
CANUS	3	2	4	3	2	1	5	3	5
Ward	1	3	3	4	5	5	3	4	5
спектральная	5	6	5	5	6	6	5	4	6
GMM	7	7	7	7	4	4	4	4	7

Метод	сквозные: П	П без AVU	Б	Б без AVU	медиана месяцев: П	П без AVU	Б	Б без AVU	худшее место
Leiden	5	5	6	5	7	6	7	7	7
паттерны	8	8	8	8	8	8	8	8	8

Оценки по шести индексам (SW, CH, S_Dbw, z_{AVI} , z_{AVU} , Q), строки — по пороговому месту на сквозных:

Метод	сквозные	троек	медиана месяцев	троек
Ward	2, 2, 2, 2, 1, 2	0	2, 1, 2, 3, 1, 3	2
KEFRiN	2, 1, 1, 2, 3, 2	1	2, 2, 1, 2, 3, 2	1
CANUS	1, 2, 2, 2, 3, 2	1	1, 2, 2, 2, 3, 2	1
k-means	1, 1, 1, 3, 2, 3	2	1, 1, 1, 3, 1, 2	1
спектральная	3, 3, 3, 1, 2, 1	3	3, 3, 3, 1, 2, 1	3
Leiden	3, 3, 2, 1, 3, 1	3	3, 3, 3, 1, 3, 1	4
GMM	2, 2, 3, 3, 1, 3	3	2, 2, 2, 2, 2, 3	1
паттерны	3, 3, 3, 3, 2, 3	5	3, 3, 3, 3, 2, 3	5

- **Первый в каждом варианте свой.** С AVU на сквозных первым идёт Ward: у него нет ни одной тройки, а единственную единицу он получает по z_{AVU} (2,1 против 8,7–23,0 у остальных). Без AVU Ward третий: его первое место держится на одном z_{AVU} .
- По медиане месяцев с AVU первым идёт k-means: у него, как и у KEFRiN, одна тройка (у k-means по z_{AVI} , у KEFRiN по z_{AVU}), но единиц четыре против одной. Без AVU k-means третий. Борда компенсирует слабость k-means на графе рекордами по SW и CH и ставит его первым на обоих периодах (на сквозных 29 очков против 28 у KEFRiN).
- Без AVU KEFRiN первая во всех четырёх вариантах (по медиане месяцев в пороговом — вровень с CANUS, в Борда — с k-means).
- **KEFRiN — единственный метод, который во всех восьми вариантах на 1-м или 2-м месте** (последний столбец). Следующие по худшему месту — k-means (4), CANUS и Ward (5).
- **Каждый метод при своём лучшем K** (Борда по K на сквозных: k-means 8, Leiden 4, Ward 7, GMM 4, спектральная 4, KEFRiN 10, CANUS 9, паттерны 4): на сквозных во всех четырёх вариантах первая спектральная с $K = 4$, второй Leiden с $K = 4$; по медиане месяцев первый k-means с $K = 8$, кроме Борда без AVU, где первая KEFRiN с $K = 10$.

6.3 Устойчивость по месяцам

Помесячные метки перенумерованы под сквозные метки того же метода венгерским алгоритмом (outputs/compare_stability.csv).

Метод, K	доля месяцев в модальном типе	ARI соседних месяцев	смен типа за 23 перехода, медиана	ARI месяц ↔ сквозные
KEFRiN, 7	0,771	0,614	7	0,363
CANUS, 7	0,734	0,631	7	0,359
GMM, 7	0,721	0,504	10	0,424
k-means, 7	0,671	0,522	10	0,312
паттерны, 7	0,642	0,550	6	0,412
Ward, 7	0,593	0,349	13	0,259
KEFRiN, 10	0,650	0,537	11	0,337
Leiden и спектральная, любое K	1 (по построению: граф один)	1	0	1

По доле месяцев в модальном типе KEFRiN устойчивее всех методов, которые кластеризуют каждый месяц заново: 0,771 против 0,734 у CANUS, 0,721 у GMM, 0,671 у k-means и 0,593 у Ward. По остальным столбцам она не первая, но рядом с лучшими: ARI соседних месяцев выше у CANUS (0,631 против 0,614), медиана смен меньше у паттернов (6 против 7). Ward самый неустойчивый: медиана 13 смен типа за 23 перехода, ARI соседних месяцев 0,349.

Здесь у всех методов одно правило выравнивания, поэтому таблица сравнивает методы между собой. В итоговых метках KEFRiN номера каждого месяца затем подогнаны под модальный тип МО (п. 7.1). Состав кластеров от этого не меняется, а смены номера перестают выглядеть сменами типа: доля месяцев в модальном типе 0,824, медиана смен 4 (outputs/dynamics/summary.json).

6.4 Итог: KEFRiN, $K = 7$

Правило выбора. Восемь вариантов рейтинга называют разных лидеров: Ward, k-means, KEFRiN. Поэтому метод выбираем так, чтобы выбор не зависел ни от правила свёртки (пороговое или Борда), ни от спорного индекса (с AVU или без), ни от периода (сквозные или медиана месяцев): метод должен стоять на 1-м или 2-м месте во всех восьми вариантах. Второе условие — устойчивость по месяцам. Задача динамическая, типы МО прослеживаются месяц за месяцем, и метод, который перекраивает типы от шума месяца, даёт ложные переходы, поэтому устойчивость здесь — содержательный критерий.

1. **Рейтинг.** Первому условию удовлетворяет только KEFRiN: места 2, 1, 2, 1 на сквозных и 2, 1, 2, 1 по медиане месяцев (п. 6.2). Первая она не везде. С AVU на сквозных первым идёт Ward: его место держится на одном z_{AVU} , а по месяцам он самый неустойчивый. По медиане месяцев с AVU первым идёт k-means, и он же первый в Борда с AVU на обоих периодах. На сквозных KEFRiN лучшая по S_Dbw и вторая по CH, z_{MQ} у неё 229 против 197 у k-means.
2. **Устойчивость.** МО проводит в модальном типе 77 % месяцев — больше, чем у любого метода, который кластеризует каждый месяц заново: у CANUS 73 %, у k-means 67 %, у Ward 59 %. Медиана смен 7 против 10 у k-means и 13 у Ward.
3. **Интерпретируемость.** У каждого типа есть центр в тех же единицах, что и признаки, поэтому профиль по Миркину (раздел 8) читается напрямую. С k-means на сквозных KEFRiN совпадает на $ARI = 0,42$ (outputs/final_choice.md): основа типов та же, граф её поправляет.
4. **$K = 7$, а не 10.** Борда по K для KEFRiN выбирает 10, потому что z_{AVI} и Q растут с K . Но при $K = 10$ падает устойчивость (модальный тип 0,65, медиана 11 смен), SW снижается до 0,095, самый малый тип уменьшается до 78 МО против 211 при $K = 7$. Если брать каждый метод при своём лучшем K , KEFRiN с $K = 10$ по медиане месяцев вторая после k-means с $K = 8$ (в Борда без AVU первая), а на сквозных 3–4-я: впереди спектральная и Leiden с $K = 4$, в пороговом — и k-means с $K = 8$ (п. 6.2). 7 — общее K сравнения и лучшее K k-means на сквозных в базовом прогоне.

Почему не остальные. Ward первый в пороговом рейтинге на сквозных с AVU, но только за счёт z_{AVU} : без AVU он третий, по медиане месяцев в пороговом пятый (с AVU и без), а по месяцам самый неустойчивый (0,593, медиана 13 смен). k-means первый в Борда и в пороговом по медиане месяцев с AVU, но в пороговом на сквозных четвёртый (две тройки, z_{AVI} и Q : проигрывает на графе) и менее устойчив (0,671). GMM на сквозных седьмой: тройки по S_Dbw, z_{AVI} и Q . Leiden и спектральная статичны (граф один), их сообщества почти не разделены по признакам (SW 0,037 и 0,045): это группы МО с синхронной динамикой, а не профили трат. CANUS ближе всех к KEFRiN по устойчивости, но в Борда с AVU он четвёртый на сквозных и пятый по медиане месяцев. Слитые паттерны последние во всех вариантах: они видят только порядок пяти долей, без уровня трат и доступности рынков, и остаются описательным слоем.

Итоговые метки — outputs/labels/final.parquet: 2 016 МО × 24 месяца, тип 0...6. Каждый месяц KEFRiN кластеризует отдельно на помесечных признаках и общем графе. Метки месяца сначала перенумеровываются под сквозное разбиение KEFRiN $K = 7$ венгерским алгоритмом, затем под модальный тип МО (п. 7.1). Номера упорядочены по убыванию числа МО-месяцев, все 7 типов непусты в каждом месяце.

6.5 Процедура

1. **Одни входы.** Все восемь методов получают одни и те же признаки (раздел 2) и один граф (раздел 3). Признаковые индексы считаются на этих признаках, графовые — на этом графе.
2. **Одно K .** Основная таблица — при общем K ; отдельно каждый метод при своём лучшем K . У Leiden нужное K даёт подбор разрешения, у паттернов — агломеративное слияние (п. 4.10), у Ward — разрез дерева, у остальных K задаётся.
3. **Два режима.** Сквозной (одно разбиение по признакам за 24 месяца) и помесечный (24 разбиения; в таблицах медиана по месяцам, значения каждого месяца — в outputs/compare_indices_full.csv).
4. **Каждое разбиение** — шесть индексов из критериев, в сыром виде и как z против перестановок (п. 5.3).
5. **Свёртка шести ранжировок в одну — пороговое агрегирование Алескерова [19].** Каждый индекс ставит методу оценку 1, 2 или 3 (лучшая, средняя или худшая треть); выше стоит метод, у которого меньше троек, при равенстве — у которого больше единиц. Правило некомпенсаторное: провал по одному индексу нельзя выкупить успехами по остальным. Для контроля рядом — сумма рангов Борда [20]. Если лидеры расходятся, показываем все варианты, а метод выбираем по правилу п. 6.4: 1-е или 2-е место во всех восьми вариантах и устойчивость по месяцам.
6. **Рядом — устойчивость по месяцам (п. 6.3).** Весь прогон сравнения с кэшем меток KEFRiN и CANUS занял 208 с на CPU (outputs/compare_meta.json).

В базовом прогоне (outputs/baseline_best_k.json, косинусный граф) K от 4 до 12 выбирали суммой рангов Борда по SW, CH, S_Dbw, z_{AVI} , z_{AVU} и Q . Для k-means лучшее $K = 7$ на сквозном периоде и 10 по медиане месяцев, для Leiden — 10 и 12. На общем графе сравнения лучшее K другое (п. 6.2), итоговое $K = 7$ обосновано в п. 6.4.

7. Динамика

Всё в этом разделе считает одна команда `.venv/Scripts/python.exe -X utf8 scripts/run_dynamics.py` (КОД `src/dynamics.py`, тесты `tests/test_dynamics.py`). Числа взяты из `outputs/dynamics/summary.json` и CSV рядом с ним: 2 016 МО, 24 месяца, 7 типов итоговой типологии.

Порядок такой: согласовать номера типов между месяцами (п. 7.1), отделить настоящие смены типа от шума (7.2–7.3), найти главные потоки между типами (7.4), описать события жизни кластеров по MONIC [23] (7.5), проверить устойчивость самих типов бутстрэпом [24] (7.6) и сезонность (7.7).

7.1 Номера типов: согласование под модальный тип МО

KEFRiN кластеризует каждый месяц отдельно, и номер кластера в месяце сам по себе ничего не значит. Сначала мы, как для всех методов в п. 6.3, перенумеровали метки каждого месяца под сквозное разбиение венгерским алгоритмом [21]. Для типов районов этого мало. Типы 0, 1, 2 и 6 в сквозном разбиении близки, и в 7 месяцах из 24 (2023-01...04, 2023-06, 2023-11 и 2024-09) алгоритм раздал им номера по кругу, хотя сами кластеры переживали месяц почти целиком. Например, МО с квартальной траекторией «6-6-1-1-1-1-1» на деле два года оставались в одном кластере: в первом полугодии 2023 года он просто получил другой номер.

Поэтому итоговые номера каждого месяца подогнаны под модальный тип МО за 24 месяца (`consensus_align`): месяцы перенумеровываются под модальный тип, модальный тип пересчитывается, и так до неподвижной точки. Состав кластеров в каждом месяце и ARI между месяцами от этого не меняются, меняются только номера. Тест `test_consensus_align_undoes_month_relabel` проверяет, что так снимается нарочно перепутанная нумерация месяцев.

KEFRiN, $K = 7$	номера под сквозное разбиение (<code>compare_stability.csv</code>)	номера под модальный тип МО (итог)
МО ни разу не сменили тип	13,8 %	25,1 %
смен за 23 перехода, медиана	7	4
доля месяцев в модальном типе	0,771	0,824

После согласования 99 % «выживаний» MONIC между соседними месяцами (п. 7.5) уходят в кластер с тем же номером.

7.2 Настоящие смены и шум

Смена считается настоящей, если новый тип держится не меньше h месяцев подряд. Короткие заходы между двумя такими эпизодами не засчитываются. Эпизод у края ряда тоже должен быть не короче h , поэтому смена в последние $h - 1$ месяцев подтвердиться не успевает: правило осторожное.

	сырые смены	$h = 2$	$h = 3$
всего смен	10 039	2 422	725
медиана на МО	4	0	0
МО без смен	25,1 %	53,8 %	76,0 %

При $h = 2$ не подтверждаются 76 % сырых смен: это заходы на один месяц и мерцание между соседними типами. При $h = 3$ остаётся 7 %. Одну смену при $h = 3$ делают 308 МО, две — 119, три и больше — 56. У 1 533 МО (76 %) всё помесечное движение укладывается в заходы на один-два месяца.

Для сравнения, паттерны Алескерова–Мячина (`outputs/jury/jury_meta.json`) дрожат гораздо сильнее. Полный порядок пяти долей МО меняет в медиане 15 раз из 23, модальный паттерн держится 25 % месяцев, весь период один паттерн сохранили 3 МО из 2 016: проценты двух-трёх категорий у многих МО близки, и соседние месяцы меняют их местами. Форма ломаной устойчивее: медиана 6 смен, модальный паттерн 58 % месяцев, 136 МО не меняли его ни разу. Помесечная типология без порога устойчивости показала бы в основном шум. По той же причине в признаках нет помесечного темпа роста (раздел 2).

7.3 Кварталы и годы

Тип квартала — модальный из трёх месяцев. При ничьей 1-1-1 берётся больший номер, как на сайте; таких МО-кварталов 271 из 16 128.

- Все 8 кварталов в одном типе провели **1 035 МО (51,3 %)**.
- **Сменили тип насовсем 76 МО (3,8 %)**: ровно одна смена, и до неё, и после не меньше двух кварталов.
- Остальные 905 МО (44,9 %) хотя бы раз возвращались или колебались.

- От квартала к кварталу в своём типе остаются 78–84 % МО, ARI соседних кварталов в среднем 0,642.

По годам модальный тип 2023 и 2024 годов совпадает у **1 748 МО (86,7 %)** и различается у 268. Из этих 268 к «насовсем» по кварталам относятся 35.

7.4 Главные потоки 2023 → 2024

Поток — МО, у которых модальный тип 2023 года один, а 2024-го другой (`transitions_year.csv`). Примеры — самые крупные по населению МО потока; если в потоке есть МО, сменившие тип насовсем, примеры берутся из них.

поток	МО	доля исходного типа	из них насовсем	где чаще	примеры
1 → 2 (районы и малые города → районы с самой высокой долей маркетплейсов)	45	13 %	13	Тверская 8, Калужская 6, Рязанская 4	Козельский р-н (Калужская), Бежецкий р-н (Тверская), Ясногорский р-н (Тульская)
0 → 1	26	7 %	3	Коми 3, Алтайский край 3, Кировская 3	Старомайнский р-н (Ульяновская), Бирилюсский р-н (Красноярский край), Пестяковский р-н (Ивановская)
2 → 1	22	6 %	3	Самарская 6, Орловская 3, Волгоградская 2	Сенгилеевский р-н (Ульяновская), Большечерниговский р-н (Самарская), Касимовский р-н (Рязанская)
6 → 5	18	11 %	2	Башкортостан 4, Татарстан 2, Красноярский край 2	Чишминский р-н (Башкортостан), Череповецкий р-н (Вологодская)
6 → 4	17	10 %	0	Приморье 5, Якутия 3, Забайкалье 3	Черногорск (Хакасия), Назарово (Красноярский край), Надеждинский округ (Приморье)

Заметный направленный сдвиг один: 1 → 2, в тип с самой высокой долей маркетплейсов. За год так перешли 45 МО, 13 из них насовсем, больше всего в Тверской, Калужской и Рязанской областях. Обратно, 2 → 1, перешли 22 МО. У 13 МО «насовсем» переход приходится на квартал между третьим 2023 года и вторым 2024-го, чаще всего на первый квартал 2024 года: 5 МО (`stability_mo.csv`).

По кварталам (`transitions_quarter.csv`, сумма за 7 пар соседних кварталов) встречные потоки сопоставимы: 1 → 2 — 300 МО-переходов и 2 → 1 — 251, 6 → 4 — 160 и 4 → 6 — 158. Это колебания пограничных МО между соседними типами, а не перетекание. Перекос есть у пары 5 → 3 (231) и 3 → 5 (130), но это разовые скачки из п. 7.7: по годам из типа 5 в тип 3 перешло одно МО.

7.5 События MONIC

Кластер *X* периода *t* «выживает» в кластере *Y* периода *t* + 1, если в *Y* перешло не меньше τ его МО и больше никто в *Y* не выжил. Если в *Y* сошлись несколько кластеров, это поглощение. Если совпадения нет, но *X* разошёлся по двум и более кластерам (каждая часть не меньше τ_{split} , вместе не меньше τ), это распад. Остальное — исчезновение, а кластер *Y*, в который никто не выжил, не влился и не распался, — появление [23].

Пороги. $\tau = 0,5$ — наименьшее значение, при котором у кластера не больше одного преемника (большинство состава); оно же принято по умолчанию у авторов MONIC. Порог части при распаде $\tau_{split} = 0,25$ выше уровня случайности: при случайной раздаче МО доля *X*, попавшая в *Y*, примерно равна $|Y|/N$, а у самого большого типа это 0,18.

- **Кварталы** (7 пар × 7 типов): 48 выживаний и 1 распад. Тип 5 во втором квартале 2023 года разошёлся между типами 3 и 5 (47 % и 49 % состава). Поглощений, исчезновений и появлений нет. В своём типе остаётся в медиане 82 % состава кластера, минимум 49 %.
- **Месяцы** (23 пары): 149 выживаний, 6 распадов, 3 поглощения (в `monic_events.csv` это 6 строк: в каждом случае два кластера сливаются в один) и 4 появления. Почти всё это тип 6, самый малый. Он распадается (2023-04, 2023-12, 2024-05) или поглощается типом 4 (2023-05) и типом 5 (2024-01, 2024-07). После поглощений и распада 2023-04 новый кластер 6 того же месяца собирается из других типов: это и есть 4 появления. Кроме него дважды распадается тип 5 (на 3 и 5 в 2023-04, на 5 и 6 в 2024-06) и один раз тип 2 (на 1 и 2 в 2023-11). На уровне кварталов из всего этого остался один распад, так что это разовые месяцы, а не сдвиги структуры.
- **Чувствительность к τ** (кварталы, `summary.json` → `monic`): при $\tau = 0,4$ выживают все 49 кластеров, при 0,6 — 44, при 0,7 — 41, при 0,8 — 32, и только с 0,6 появляются исчезновения и появления. Вывод о том, что типы переживают кварталы, от порога в разумных пределах не зависит: в медиане около 80 % состава типа остаётся на месте.

7.6 Устойчивость: бутстрэп KEFRiN

Схема Хеннига [24], но с подвыборками вместо бутстрэпа. Берутся 80 % МО без возвращения: при выборке с возвращением у графового метода в графе дублировались бы узлы. На них заново запускается KEFRiN с $K = 7$ и теми же параметрами на подграфе `lagcorr_knn`. Прогонов 100 на сквозных признаках и по 10 на четырёх месяцах (2023-01, 2023-07, 2024-01, 2024-07); результаты лежат в `bootstrap.csv`.

что сравниваем	ARI
один месяц: KEFRiN на 80 % МО против KEFRiN на всех	0,67–0,81 по четырём месяцам, в среднем 0,76
соседние месяцы, итоговые метки	0,614 (минимум 0,477)
соседние кварталы, модальные типы	0,642
сквозные признаки: 80 % МО против всех, 100 прогонов	0,69 (5–95 %: 0,51–0,82)
тот же месяц: KEFRiN против CANUS / k-means / Leiden / паттернов	0,53 / 0,42 / 0,28 / 0,25

- Соседние месяцы согласуются (0,61) лишь немного хуже, чем месяц сам с собой, когда из него выбросили 20 % МО (0,67–0,81). Помесячная разница ненамного больше собственного шума метода, и это ещё один довод, что большая часть помесечных смен — шум.
- Два метода на одном месяце расходятся сильнее, чем один метод на соседних месяцах: даже с CANUS ARI 0,53. От выбора метода разбиение зависит больше, чем от месяца.
- Устойчивость типов** — средний Жаккар типа с лучшим совпадением на подвыборке; ниже 0,6 тип считается неустойчивым [24]. На сквозных признаках: 4 — 0,86, 1 — 0,80, 0 — 0,77, 2 — 0,73, 3 — 0,71, **6 — 0,59, 5 — 0,56**. На четырёх месяцах все типы не ниже 0,63, у типа 6 — от 0,65 до 0,77. Неустойчивые типы 5 и 6 — те же, что дают почти все помесечные события MONIC (п. 7.5). Север (тип 4) и Москва (тип 3) устойчивы.
- Ограничение: по месяцам это 4 месяца из 24 и по 10 прогонов, то есть грубая оценка. На сквозных признаках прогонов 100.

7.7 Сезонность

Помесячные признаки нормированы внутри месяца (раздел 2), так что общая для страны сезонность уже вычтена. Проверяется относительная: уходят ли одни и те же МО в какой-то тип каждое лето или каждый декабрь (`seasonal.csv`).

- Такого типа нет.** Профиль числа МО в типе по календарным месяцам в 2023 и 2024 годах не повторяется: корреляция отклонений между годами от −0,62 до +0,30 по типам. Разница «лето минус остальные месяцы» не больше 1,5 п. п. доли МО, «декабрь минус остальные» — не больше 1,6 п. п.
- Крупные помесечные скачки разовые. Тип 3 вырастает с ≈ 240 до ≈ 350 МО в 2023-04, 2023-09 и 2024-10: каждый раз 110–120 МО приходят из типа 5 (оба типа городские) и держатся месяц-два. Тип 4 теряет 80–120 МО в пользу типа 6 в 2023-04, 2023-10 и 2024-07. На один и тот же календарный месяц в двух годах эти скачки не приходятся.
- Одних и тех же МО, которые меняют тип **летом в обоих годах**, 26: 4 → 6 — 6 МО, в том числе Чусовской и Великоустюгский районы и Заринск; 5 → 4 — 4 МО, в том числе Находкинский округ и Ханты-Мансийск. **В декабре обоих лет** таких 37, из них 1 → 0 — 11 МО, по два в Марий Эл, Вологодской и Кировской областях. Это 1–2 % МО. Туристических или северных типов, куда МО стабильно уходят по сезону, в этой типологии нет.

7.8 Что из этого следует

- Помесячная типология дрожит в основном от шума: 76 % МО при $h = 3$ не меняют тип ни разу. Для карты и выводов годятся модальный тип МО (раздел 8), тип квартала (так делает сайт) или смены, которые держатся от трёх месяцев.
- Настоящих направленных переходов мало. Заметен один: 1 → 2 в центральных областях, 45 МО за год, 13 насовсем. Остальное — колебания на границах соседних типов.
- Слабые места типологии — типы 5 и 6: у них ниже бутстрэп-устойчивость, и на них приходится почти все события MONIC. Тип 6 стоит читать как переходный (п. 8.7).

8. Интерпретация типов

Всё в этом разделе считает одна команда `.venv/Scripts/python.exe -X utf8 scripts/run_interpret.py` (код `src/interpret.py`, тесты `tests/test_interpret.py`, около 2 с). Таблицы лежат в `outputs/interpret/`, названия и описания — в `outputs/types.csv`.

8.1 Как считали

- **Тип МО** — модальный тип за 24 месяца. При равенстве месяцев (23 МО) берётся больший номер, как на карте сайта. Профили считаются по МО, а не по МО-месяцам, поэтому числа немного отличаются от таблицы в `outputs/final_choice.md`.
- **Среднее по стране** — невзвешенное среднее по 2 016 МО. В скобках в таблице 8.2 — отношение к нему.
- **Траты на жителя** — геометрическое среднее по МО их средних трат за 24 месяца. **Рост** — медиана по МО отношения средних месячных трат 2024 и 2023 годов.
- **Росстат** в кластеризацию не входил (раздел 2), поэтому совпадение типов с ним — независимая проверка, а не следствие построения.
- **Название — после чисел.** Каждое утверждение названия проверяется кодом по профилю (`check_names` в `scripts/run_interpret.py`): если прогон с другими метками перестанет им соответствовать, скрипт остановится.

8.2 Профили семи типов

Доли категорий в итоге трат, в скобках — отношение к среднему по 2 016 МО. В таблице названия типов сокращены, полные — в п. 8.7 и `outputs/types.csv`.

Тип	МО	продукты	маркетплейсы	общепит	транспорт	здоровье	прочее	траты на жителя, ₽/мес	рост 2024/2023	доступность рынков	население, медиана
0. Сельские, самые низкие траты	377	49,6 % (1,13)	12,6 % (0,91)	1,9 % (0,56)	5,4 % (0,92)	4,9 % (1,01)	25,7 % (0,91)	20 142 (0,75)	+12,9 %	300	16 360
1. Районы и малые города	342	48,1 % (1,10)	16,2 % (1,17)	1,9 % (0,56)	4,6 % (0,79)	4,2 % (0,87)	25,0 % (0,88)	23 701 (0,88)	+13,3 %	322	15 142
2. Сельские, маркетплейсы	357	46,2 % (1,05)	17,6 % (1,27)	1,8 % (0,53)	5,5 % (0,95)	5,4 % (1,10)	23,6 % (0,84)	21 614 (0,80)	+14,5 %	350	17 939
3. Москва и соседние центры	251	34,6 % (0,79)	13,2 % (0,96)	6,5 % (1,95)	7,1 % (1,22)	5,4 % (1,11)	33,1 % (1,17)	43 089 (1,60)	+17,5 %	586	89 544
4. Север и Восток	269	43,5 % (0,99)	10,5 % (0,76)	3,7 % (1,12)	5,1 % (0,87)	4,1 % (0,84)	33,0 % (1,17)	33 977 (1,26)	+14,2 %	181	26 470
5. Петербург и крупные города	277	36,3 % (0,83)	12,0 % (0,87)	6,2 % (1,87)	7,1 % (1,21)	5,5 % (1,13)	32,8 % (1,16)	34 738 (1,29)	+17,3 %	342	76 770
6. Районы Сибири	143	44,4 % (1,01)	12,7 % (0,92)	2,7 % (0,82)	7,5 % (1,28)	4,4 % (0,90)	28,3 % (1,00)	23 871 (0,89)	+15,9 %	222	23 304
Все 2 016 МО	2 016	43,9 %	13,8 %	3,3 %	5,8 %	4,9 %	28,3 %	26 958	+15,1 %	323	23 704

Типы лежат на одной оси «город — село»: от типа 3 с общепитом 6,5 % и тратами 43 тыс. ₽ до типа 0 с общепитом 1,9 % и тратами 20 тыс. ₽. Вторая ось — удалённость: типы 4 и 6 отделяет от остальных низкая доступность рынков (181 и 222 при медиане 323), а не структура трат. Самые быстрые по росту трат — городские типы 3 и 5 (+17,5 % и +17,3 %), самый медленный — тип 0 (+12,9 %). Разрыв между городом и селом за два года вырос.

8.3 Где типы на карте

Карта типов — на сайте проекта (`site/`). Словами (`outputs/interpret/profiles.csv`, `examples.csv`, `capitals.csv`):

- **Тип 3** — сплошное пятно Москвы (142 из 144 внутригородских территорий) и Подмосковья (46 из 52 МО области). К ним примыкают 9 областных центров в 161–493 км от Москвы: Тверь, Калуга, Тула, Владимир, Рязань, Орёл, Смоленск, Тамбов, Великий Новгород. Остальные МО типа — пригородные районы крупных городов (Рязанский, Ярославский, Тюменский, районы Ленинградской области у Петербурга), города вокруг Москвы (Обнинск, Ковров, Новомосковский) и 4 окраинные территории Петербурга. Столицы типа 3 не богаче столиц типа 5: медианная зарплата 62,7 тыс. ₽ против 67,6 тыс. ₽, траты 35,1 против 34,0 тыс. ₽. От столиц типа 5 их отличают близость к Москве (медиана 184 км против 1 228 км) и доступность рынков (408 против 310).
- **Тип 5** — Петербург (94 из 98 внутригородских территорий) и 43 из 64 региональных столиц выборки с городами-спутниками: Березовский и Верхняя Пышма у Екатеринбурга, Волжский у Волгограда.
- **Тип 4** — север и восток: 79 % МО восточнее 60° в. д. (по выборке 31 %) и 39 % севернее 60° с. ш. (по выборке 8 %). Вся Якутия (29 из 29), 19 из 22 МО Югры, 21 из 33 МО Приморья. 10 региональных столиц, у них самые высокие траты и зарплаты среди столиц (46,7 и 108,3 тыс. ₽).

- **Тип 6** — 74 % МО восточнее 60° в. д.: Иркутская область (19 из 39), Забайкалье (17 из 28), Республика Алтай (10 из 11), Тыва (9 из 10), Алтайский край (10 из 65). Исключение на западе — Башкортостан (17 из 61).
- **Тип 0** — пояс от Удмуртии (21 из 27) и Кировской области (31 из 43) до Омской области (26 из 33) и Алтайского края (47 из 65), 46 % МО восточнее 60° в. д.
- **Тип 1** — Нечерноземье северо-запада и центра и Свердловская область (23 из 64): Ивановская (20 из 26), Вологодская (17 из 25), Тверская (17 из 37), Костромская, Псковская, Новгородская, Смоленская, Архангельская области. Среди МО типа 17 % городских округов, больше, чем в типах 0 и 2 (6 % и 10 %).
- **Тип 2** — европейская часть, Поволжье и юг: Саратовская (32 из 39), Волгоградская (29 из 35), Нижегородская (27 из 50), Пензенская (23 из 25), Тамбовская (21 из 24), Ставрополье (20 из 33), Мордовия, Рязанская область. Восточнее 60° в. д. только 4 % МО.

Примеры МО. Типичные ближе всего к центру типа в пространстве 15 сквозных z-признаков. Пограничные меньше всего отличаются по расстоянию до своего центра и до ближайшего чужого; стрелка показывает, к какому типу МО ближе по признакам. KEFRiN учитывает ещё и граф, поэтому пограничное МО может лежать ближе к чужому центру.

Тип	5 типичных МО	3 пограничных МО → ближайший чужой тип
0	Татищевский р-н (Саратовская обл.), Тальменский р-н (Алтайский край), Уйский р-н (Челябинская обл.), Шарканский р-н (Удмуртия), Ташлинский р-н (Оренбургская обл.)	Гурьевский и Яшкинский м. о. (Кемеровская обл.) → 6; Увинский р-н (Удмуртия) → 6
1	Сокольский г. о. (Нижегородская обл.), Починковский р-н (Смоленская обл.), г. Козьмодемьянск (Марий Эл), Южский р-н (Ивановская обл.), г. Галич (Костромская обл.)	Мамоновский г. о. (Калининградская обл.) → 0; Похвистневский р-н (Самарская обл.) → 2; Ермаковский р-н (Красноярский край) → 6
2	Жердевский м. о. и г. Кирсанов (Тамбовская обл.), Барышский р-н (Ульяновская обл.), Николаевский и Котельниковский р-ны (Волгоградская обл.)	Сергиевский р-н (Самарская обл.) → 0; Ибресинский м. о. (Чувашия) → 0; Новоспасский р-н (Ульяновская обл.) → 1
3	м. о. Силино и Северное Медведково (Москва), г. о. Люберцы, Пушкинский и Дзержинский (Московская обл.)	Прионежский р-н (Карелия) → 6; г. Смоленск → 5; г. Камышин (Волгоградская обл.) → 5
4	г. о. Ухта (Коми), Шкотовский м. о. (Приморье), Советско-Гаванский и Ванинский р-ны (Хабаровский край), Междуреченский г. о. (Кемеровская обл.)	Красноармейский м. о. (Приморье) → 0; Октябрьский р-н (Еврейская АО) → 0; Мотыгинский р-н (Красноярский край) → 0
5	Колпино (Петербург), г. о. Березовский и Верхняя Пышма (Свердловская обл.), г. о. Самара, г. Ижевск	Среднеуральск (Свердловская обл.) → 0; Заинский и Пестречинский р-ны (Татарстан) → 6
6	Алтайский р-н (Алтайский край), Усть-Абаканский р-н (Хакасия), Промышленновский м. о. (Кемеровская обл.), Заларинский р-н и г. о. Зима (Иркутская обл.)	Вагайский р-н (Тюменская обл.) → 0; Усть-Ишимский р-н (Омская обл.) → 0; Петропавловский р-н (Алтайский край) → 0

8.4 Профиль по Миркину

Признаки — 15 сквозных z-оценок (раздел 2). Для типа k и признака v считаем отклонение центра от общего среднего в σ , $(c_{kv} - \bar{y}_v)/s_v$, и вклад в разброс $B_{kv} = |C_k| (c_{kv} - \bar{y}_v)^2$ в долях от общего разброса $T = \sum_{i,v} (y_{iv} - \bar{y}_v)^2 = 29\,463$ [13]. Все семь типов вместе объясняют **43,1 %** разброса (outputs/interpret/mirkin.csv, summary.json).

Тип	вклад типа в разброс	три признака с наибольшим вкладом: отклонение в σ (вклад, % от T)
0	5,8 %	уровень трат −0,92 (1,08); доля продуктов +0,87 (0,97); тренд доли маркетплейсов +0,78 (0,76)
1	4,9 %	доля транспорта −0,93 (0,99); доля здоровья −0,83 (0,79); доля маркетплейсов +0,73 (0,61)
2	5,0 %	доля маркетплейсов +1,13 (1,56); доля прочего −0,91 (1,01); доля общепита −0,70 (0,60)
3	13,4 %	доступность рынков +1,90 (3,03); уровень трат +1,48 (1,87); доля общепита +1,41 (1,68)
4	5,0 %	доступность рынков −1,14 (1,18); доля маркетплейсов −1,00 (0,91); доля здоровья −0,96 (0,84)
5	7,6 %	доля общепита +1,29 (1,55); доля продуктов −1,15 (1,24); доля транспорта +0,93 (0,81)
6	1,4 %	доля транспорта +1,20 (0,69); доступность рынков −0,79 (0,30); доля здоровья −0,61 (0,18)

Что видно. Тип 3 — самый выраженный: почти треть объяснённого разброса. Первый по вкладу признак у него — доступность рынков, за ней уровень трат и доля общепита. Типы районов 0, 1 и 2 различаются по разным осям: у 0 — уровень трат, у 1 — транспорт и здоровье, у 2 — маркетплейсы. Общая их черта — мало общепита (−0,65σ, −0,65σ и −0,70σ), она одинакова у всех трёх и потому их не разделяет. Тип 6 выражен слабее всех (1,4 %), и в нём МО реже всего остаются в своём типе: в среднем 71 % месяцев против 82 % по всем МО (outputs/interpret/mo_types.csv). Из трендов в первую тройку попал только один: доля маркетплейсов у типа 0 растёт быстрее, чем где-либо (+0,78σ).

8.5 Описание типов формальными понятиями (FCA)

Контекст. 2 016 МО × 40 бинарных атрибутов. Десять признаков в исходных единицах — шесть долей, уровень трат, доступность рынков, тренды доли маркетплейсов и уровня трат — переведены порядковой шкалой по квартилям: «нижняя четверть», «ниже медианы», «выше медианы», «верхняя четверть». Пороги — `outputs/interpret/fca_scale.csv`.

Понятия. Всю решётку не строим, она огромна. Перебираем все наборы до трёх атрибутов, замыкаем каждый ($B \mapsto B''$) и получаем 7 894 различных понятия (A, B) [25]. Для типа C_k у понятия есть точность $|A \cap C_k|/|A|$ и покрытие $|A \cap C_k|/|C_k|$.

Устойчивость [26]: $\sigma(A, B)$ — доля подмножеств объёма A , у которых то же содержание B . Перебор $2^{|A|}$ подмножеств при объёмах в сотни МО невозможен, поэтому считаем оценки Бузмакова, Кузнецова и Наполи [29]. $\Delta_m = |A \setminus m'|$ — сколько МО из объёма не имеют атрибута $m \notin B$; тогда $1 - \sum_m 2^{-\Delta_m} \leq \sigma \leq 1 - 2^{-\Delta}$, где $\Delta = \min_m \Delta_m$. Δ читается просто: столько МО надо убрать из объёма, чтобы описание стало другим. Точный перебор и оценки сверены на игрушечном контексте с известной решёткой (`tests/test_interpret.py`).

Отбор. Для каждого типа берём понятия с точностью не ниже 0,5 и нижней оценкой $\sigma \geq 0,99$ и ранжируем по гармоническому среднему точности и покрытия. По три лучших правила на тип — в `outputs/interpret/fca_rules.csv`, здесь первое:

Тип	Тип = ... (содержание понятия)	МО в объёме	из них этого типа	точность	покрытие	Δ	$\sigma \geq$
0	доля продуктов выше медианы ∧ доля маркетплейсов ниже медианы ∧ уровень трат ниже медианы	292	234	0,80	0,62	62	1,000
1	доля маркетплейсов выше медианы ∧ доля транспорта ниже медианы ∧ доля здоровья ниже медианы	394	263	0,67	0,77	93	1,000
2	доля маркетплейсов выше медианы ∧ доля здоровья выше медианы ∧ доля прочего ниже медианы	341	259	0,76	0,73	38	1,000
3	уровень трат выше медианы ∧ доступность рынков в верхней четверти ∧ тренд доли маркетплейсов ниже медианы	365	230	0,63	0,92	7	0,990
4	доля прочего выше медианы ∧ уровень трат выше медианы ∧ доступность рынков в нижней четверти	261	207	0,79	0,77	40	1,000
5	доля маркетплейсов в нижней четверти ∧ доля транспорта выше медианы ∧ тренд уровня трат выше медианы	233	145	0,62	0,52	13	1,000
6	доля транспорта в верхней четверти ∧ доля здоровья ниже медианы ∧ доступность рынков ниже медианы	82	62	0,76	0,43	17	1,000

Как читать. Правило для типа 4: «доля прочего выше медианы, траты выше медианы, доступность рынков в нижней четверти страны». Под него подходят 261 МО, из них 207 — тип 4 (точность 0,79), и это 77 % всех МО типа. Чтобы описание изменилось, из объёма надо убрать не меньше 40 МО.

- **Лучше всего описываются типы 4, 0 и 2:** точность 0,76–0,80 при покрытии 0,62–0,77, Δ от 38 до 62.
- **Типы 3 и 5 квартилями не разделяются.** В объёме правила типа 3 кроме 230 МО самого типа 103 МО типа 5 (`extent_by_type` в `fca_rules.csv`). Описание «общепит выше медианы ∧ доступность рынков в верхней четверти» на 89 % состоит из МО типов 3 и 5 (235 и 109 из 385). Это описание «города», а граница между двумя городскими типами лежит внутри верхней четверти доступности. Порядковая шкала по квартилям её не видит; её видит числовая узорная структура [30], это следующий шаг.
- **Тип 6 описывается хуже всех:** покрытие 0,43, объём правила всего 82 МО. Это согласуется с его малым вкладом по Миркину (п. 8.4).
- У всех правил нижняя оценка σ не ниже 0,99: при объёмах в сотни МО описание почти не зависит от отдельных МО. Различает правила Δ : у правила типа 3 оно равно 7, у правила типа 1 — 93.

8.6 Внешняя проверка: Росстат и индекс мобильности

Показатели Росстата за 2023 год (раздел 1.4): медианная зарплата, работники на жителя, население, доли занятых по разделам ОКВЭД2 без малого предпринимательства. Для каждого показателя — критерий Краскела–Уоллиса по семи типам и размер эффекта $\eta_H^2 = (H - k + 1)/(n - k)$ [31]; ориентиры: 0,01 — малый, 0,06 — средний, 0,14 — большой. При n в сотни и тысячи p у всех показателей меньше 0,01, поэтому смотрим на η_H^2 . Доли занятых Росстат часто скрывает, и их n меньше 2 016 (`outputs/interpret/rosstat_kw.csv`, медианы — `rosstat_medians.csv`).

Показатель (медиана)	η_H^2	n	0	1	2	3	4	5	6	все
зарплата 2023, тыс. Р	0,553	2 016	42,6	47,1	42,2	103,1	80,5	68,1	50,6	51,3
зарплата к медиане МО своего региона	0,092	2 016	0,96	0,99	0,97	1,08	1,05	1,15	0,96	1,00

Показатель (медиана)	η_H^2	n	0	1	2	3	4	5	6	все
население, тыс.	0,437	2 016	16,4	15,1	17,9	89,5	26,5	76,8	23,3	23,7
работники на жителя	0,178	1 986	0,156	0,172	0,145	0,188	0,267	0,209	0,161	0,172
занятые: сельское и лесное хозяйство, %	0,236	1 079	10,3	8,7	11,4	2,2	2,8	1,2	4,4	6,3
занятые: добыча, %	0,413	321	9,6	7,8	7,0	0,4	22,5	2,0	21,6	8,2
занятые: обрабатывающие производства, %	0,081	1 141	9,3	17,6	16,2	13,9	8,2	16,8	6,7	12,9
занятые: торговля, %	0,331	1 926	3,5	3,9	4,0	10,5	2,9	7,2	3,1	4,2
занятые: транспорт и хранение, %	0,021	1 461	5,7	6,6	6,6	5,5	8,9	6,9	5,8	6,4
занятые: гостиницы и общепит, %	0,017	801	1,0	0,9	0,9	1,0	1,2	0,9	0,7	0,9
занятые: информация и связь, %	0,091	1 041	1,0	0,8	0,7	1,8	0,6	1,3	0,8	0,8
занятые: госуправление, %	0,223	1 954	14,4	12,8	13,0	5,6	10,1	7,4	13,5	11,7
занятые: образование, %	0,257	2 004	25,5	18,9	21,2	12,4	15,5	14,7	26,3	19,5
занятые: здравоохранение, %	0,134	1 786	14,9	13,3	15,8	9,8	10,7	11,4	15,5	13,2

Ещё в файле: зарплата 2024 ($\eta_H^2 = 0,584$), строительство (0,026), финансы (0,080), профессиональная и научная деятельность (0,053).

Что сходится с названиями.

- **Уровень трат следует за зарплатой.** Ранговая корреляция трат на жителя и зарплаты по 2 016 МО 0,86, по медианам семи типов 0,93 (summary.json). Хотя зарплаты в признаках не было, типы разошлись по ней сильнее, чем по любому другому показателю Росстата.
- **Типы районов 0, 1, 2 — действительно село:** в сельском хозяйстве занято 8,7–11,4 % против 1,2–2,8 % в типах 3, 4 и 5, медианное население 15–18 тыс. человек.
- **Городские типы 3 и 5 — действительно города:** население 90 и 77 тыс., в торговле занято 10,5 % и 7,2 % при медиане 4,2 %. Зарплата в них выше медианы МО своего региона на 8 % и 15 %: это центры своих регионов, а не просто богатые регионы. У типа 3 заметно больше занятых в ИТ и связи (1,8 %) и в профессиональной деятельности.
- **Тип 4 — ресурсный север:** в добыче занято 22,5 %, зарплата 80 тыс. Р — вторая после типа 3, работников на жителя больше всех (0,267).
- **В типах 0 и 6 больше всего занятых в бюджетном секторе:** образование 25,5 % и 26,3 % занятых, госуправление 14,4 % и 13,5 % — выше всех.

Что не сходится или требует оговорки.

- **Общепит.** Доля общепита в тратах меняется между типами от 1,8 % до 6,5 %, а доля занятых в общепите по Росстату почти одинакова ($\eta_H^2 = 0,017$). Росстат не учитывает малый бизнес, а кафе и столовые — в основном он. Поэтому общепит в тратах — признак городского образа жизни, а не отрасли, которую видит Росстат.
- **Транспорт у типа 6.** По доле транспорта в тратах тип 6 первый (7,5 %), а доля занятых в транспорте у него на уровне страны (5,8 % при 6,4 %). Это траты жителей, а не местная отрасль. Чем они вызваны, по нашим данным сказать нельзя. Росстат добавляет к описанию типа другое: в добыче там занято 21,6 %, почти как в типе 4. Тип 6 — это не только сельские, но и ресурсные районы Сибири.
- **Траты на севере отстают от зарплаты.** Траты типов 4 и 5 почти равны (34,0 и 34,7 тыс. Р), а медианная зарплата в типе 4 выше на 18 % (80,5 против 68,1 тыс. Р). Возможные причины — больше наличных, другой уровень цен, северные надбавки, которые не идут в местное потребление. Проверить их по нашим данным нечем.
- **Работники на жителя в типе 4 (0,267)** выше, чем в городах. Похоже на вахту, когда работник учтён по месту работы, а живёт в другом МО. Это гипотеза, данных о вахте у нас нет.
- **Тип 2 не чисто аграрный:** в обработке занято 16,2 % против 9,3 % в типе 0. Название говорит о структуре трат (маркетплейсы), а не об отрасли.

Индекс мобильности СберИндекса (п. 1.5) есть у 274 МО типологии, все они на Северо-Западе. Медиана за 2024 год — 5,6 км в типе 3 и 4,7 км в типе 5, 1,0 км в типе 4 и 0,55–0,69 км в типах районов 0, 1, 2 и 6; $\eta_H^2 = 0,68$. Треть этого пересечения — внутригородские территории Петербурга, и без них эффект меньше, но остаётся большим: $\eta_H^2 = 0,37$ при $n = 177$, города (3,3 и 3,8 км в типах 3 и 5) по-прежнему впереди районов. В типах 0, 2 и 6 здесь всего 16, 7 и 3 МО, так что это проверка оси «город — район» на одном округе, а не каждого типа (outputs/interpret/mobility_check.csv, scripts/check_mobility.py).

8.7 Семь типов местной экономики

- **0. Сельские районы с самыми низкими тратами** (377 МО). Бюджетная экономика аграрных районов Урала, Приволжья и юга Сибири: занятые в образовании и госуправлении, сельском хозяйстве; зарплата 42,6 тыс. Р, траты 0,75 среднего. Половина трат — продукты. Маркетплейсы пока ниже среднего, но их доля растёт быстрее всего.
- **1. Районы и малые города: транспорт и здоровье ниже среднего** (342). Нечерноземье северо-запада и центра и Свердловская область, самое малое население (медиана 15 тыс.), в обработке занято 17,6 %. Из этого типа в тип 2 идёт единственный заметный поток 2023 → 2024 (п. 7.4).
- **2. Сельские районы с самой высокой долей маркетплейсов** (357). Районы Поволжья, Центра и юга, где маркетплейсы берут 17,6 % трат. Зарплата та же, что в типе 0 (42,2 тыс. Р), но заметнее обрабатывающая промышленность.
- **3. Москва, Подмоскowie и соседние областные центры** (251). Самые высокие траты (43 тыс. Р, 1,60 среднего) и доступность рынков, общепит вдвое выше среднего. Торговля, ИТ и профессиональные услуги. Кроме столицы — 9 областных центров в 161–493 км от Москвы и пригороды крупных городов: общее у них не доход, а близость к московскому рынку.
- **4. Север и Восток: высокие траты при худшей доступности рынков** (269). Добывающие территории Якутии, Югры, Ямала и Дальнего Востока: зарплата 80 тыс. Р, траты 1,26 среднего, меньше всего маркетплейсов и больше «прочего». Самый устойчивый тип в бутстрэпе (п. 7.6).
- **5. Петербург и крупные города** (277). Петербург и две трети региональных столиц: общепит и транспорт выше среднего, траты 1,29 среднего, зарплата на 15 % выше медианы своего региона. Граница с типом 3 размыта: в бутстрэпе тип неустойчив, и в отдельные месяцы сотня его МО уходит в тип 3 (п. 7.6–7.7).
- **6. Районы Сибири: транспорт выше среднего, доступность рынков низкая** (143). Сельские и добывающие районы Иркутской области, Забайкалья, Алтая и Тывы. Самый слабо выраженный и наименее устойчивый тип. По примерам и объёмам FCA-правил он граничит с типами 0 и 4, и читать его лучше как переходный между ними.

9. Воспроизводимость

Всё запускается из корня проекта одной командой, инструкция — в README.md. Гиперпараметры лежат в YAML (configs/baseline.yaml, configs/jury.yaml, configs/compare.yaml), seed 42 везде, коммиты чужого кода закреплены. Контрольные суммы SHA-256 скачанных файлов лежат в data/raw/SHA256SUMS; этот файл входит в репозиторий, повторное скачивание 30.09 совпало со всеми 14 суммами. Проверку TLS нигде не отключали: сайты Сбера подписаны корнем Минцифры, его сертификат и промежуточный сертификат sberindex.ru лежат в certs/.

```
python -m venv .venv
.venv/Scripts/python.exe -m pip install -r requirements.txt # точные версии; torch — сборка для CPU
.venv/Scripts/python.exe -X utf8 scripts/run_all.py          # все шаги ниже, после каждого проверка его файлов
```

run_all.py вызывает шаги по порядку и останавливается, если шаг упал или не записал свои файлы. Флаги: --skip-download (данные уже скачаны), --quick (укороченный прогон тяжёлых шагов в outputs/quick/, полные результаты не трогает), --fresh (пересчитать кэши KEFRiN, CANUS и бутстрэпа). Те же шаги вручную:

```
.venv/Scripts/python.exe -X utf8 scripts/download_data.py # data/raw и SHA256SUMS
.venv/Scripts/python.exe -X utf8 scripts/build_panel.py  # data/processed, data/geo
.venv/Scripts/python.exe -X utf8 scripts/fetch_external.py # код KEFRiN и CANUS в external/
.venv/Scripts/python.exe -X utf8 scripts/run_baseline.py  # k-means, Leiden, индексы, сравнение сетей
.venv/Scripts/python.exe -X utf8 scripts/run_jury.py      # KEFRiN, CANUS, паттерны
.venv/Scripts/python.exe -X utf8 scripts/run_compare.py  # сравнение восьми методов и итоговая типология
.venv/Scripts/python.exe -X utf8 scripts/run_interpret.py # профили, Миркин, FCA, проверка Росстатом, названия
.venv/Scripts/python.exe -X utf8 scripts/run_dynamics.py  # переходы, MONIC, устойчивость, бутстрэп
.venv/Scripts/python.exe -X utf8 scripts/check_mobility.py # индекс мобильности как внешняя проверка типов
.venv/Scripts/python.exe -X utf8 scripts/prepare_geo.py  # геометрия для сайта
.venv/Scripts/python.exe -X utf8 scripts/build_site.py   # данные сайта
.venv/Scripts/python.exe -X utf8 scripts/build_pdf.py    # PDF отчёта и лендинга (нужен Chrome)
.venv/Scripts/python.exe -X utf8 -m pytest -q tests      # 48 проверок
```

Время замерено 30.09.2026 на Intel Core i5-12400F (12 потоков) без GPU, по 3 воркера jobjlib (n_jobs в configs/baseline.yaml и configs/compare.yaml; каждый воркер занимает около 0,5 ГБ памяти, перед тяжёлыми шагами run_all.py ждёт, пока освободится хотя бы 2 ГБ). Машина была занята и другими программами, поэтому указан разброс:

Шаг	Время на CPU
download_data.py: архивы Сбера, API СберИндекса, три таблицы Росстата по HTTP Range, всё с нуля	62 с
build_panel.py	18–40 с

Шар	Время на CPU
<code>fetch_external.py</code> : клон KEFRiN и CANUS с нуля	24 с
<code>run_baseline.py</code> : 25 периодов $\times K$ от 4 до 12 $\times$ два метода, индексы с перестановками, сравнение восьми графов	131–153 с
<code>run_jury.py</code> : KEFRiN, CANUS, паттерны (паттерны меньше 1 с)	395–870 с
<code>run_compare.py</code> : восемь методов, индексы с перестановками, рейтинги, итоговые метки; с кэшем меток KEFRiN и CANUS / без кэша (<code>--fresh</code> , 162 запуска)	208 с / 1 195 с
<code>run_interpret.py</code> : профили, Миркин, 7 894 понятия FCA, Краскел–Уоллис	1–3 с
<code>run_dynamics.py</code> : с кэшем бутстрэпа / без кэша (140 подвыборок $\times$ KEFRiN)	2–5 с / 555 с
<code>check_mobility.py</code>	2 с
<code>prepare_geo.py</code> и <code>build_site.py</code>	3–4 с
весь конвейер <code>run_all.py --skip-download</code> , кэши на месте	1 164 с (19 мин)
весь конвейер <code>run_all.py --skip-download --fresh</code> , без кэшей	2 304 с (38 мин)
<code>run_all.py --skip-download --quick</code>	77–108 с
тесты	48 проверок, 5–25 с

Ward, GMM и спектральная добавлены после замера всего конвейера и времени без кэша: прогон `run_compare.py` с кэшем вырос с 111–114 до 208 с, остальные шаги они не затрагивают.

Повторные прогоны `run_all.py --skip-download`, с кэшами и без них, при 12 и 3 воркерах воспроизвели байт в байт панель, все метки, индексы, рейтинги, профили, динамику и данные сайта. Отличаются только поля с временем счёта и датой сборки, а у пересчитанного кэша меток KEFRiN и CANUS — порядок строк (содержание то же). Метки Ward, GMM и спектральной, пересчитанные отдельным процессом, совпали с сохранёнными во всех 219 разбиениях.

Что проверяют тесты:

- `tests/test_panel.py` (6): нет дублей; месяцы подряд, 24; у каждого МО сбалансированной части 24×7 строк; пять категорий и «Прочее» дают итог; значения положительны; каждый МО панели есть в справочнике.
- `tests/test_icvi.py` (13): см. п. 5.3 и 5.4.
- `tests/test_jury.py` (10): паттерны на игрушке с известным ответом, инвариантность к монотонному преобразованию, порог равенства, устойчивость; kNN-граф; KEFRiN и CANUS восстанавливают два явных кластера; быстрая норма градиента CANUS совпадает с autograd; метки покрывают все МО.
- `tests/test_compare.py` (7): пороговое агрегирование и Борда на игрушках с известным ответом, слияние паттернов только соседних порядков по Уорду, перенумерация и устойчивость меток, итоговые метки покрывают все МО-месяцы; Ward, GMM и спектральная на трёх явных кластерах дают ровно K меток, находят кластеры и повторяются при том же seed.
- `tests/test_dynamics.py` (6): подтверждённые смены при $h = 2$ и $h = 3$ на рядах с известным ответом; модальный тип периода и классы траекторий; события MONIC на игрушке с известными выживанием, поглощением, распадом, исчезновением и появлением, и те же события при перестановке номеров; Жаккар типов; согласование номеров снимает нарочно перепутанную нумерацию месяцев.
- `tests/test_interpret.py` (6): решётка понятий игрушечного контекста совпадает с выписанной вручную; точная устойчивость на ней равна посчитанной руками и лежит между оценками через Δ ; из содержания убираются следствия шкалы; вклады Миркина в сумме дают R^2 ; профили считаются на всех 7 типах (на синтетике и на итоговых метках), у каждого типа 5 типичных и 3 пограничных МО.

Лицензии: код KEFRiN и CANUS в репозиторий не входит (п. 4.9), его клонирует `scripts/fetch_external.py`. Репозиторий выпущен под GPL-3.0 (файл `LICENSE`): мы зависим от `leidenalg` (GPL-3.0), а формулы графовых индексов сверены с библиотекой `Pattern` (GPL-3.0). Данные СберИндекса, включая справочник границ МО, — CC BY-SA 4.0, Росстата — CC BY 4.0; производные данные в `data/processed`, `outputs` и `site/data` — CC BY-SA 4.0.

10. Ограничения и что дальше

Ограничения.

- Индекс мобильности СберИндекса есть только у 297 МО Северо-Запада (274 из 2 016 МО типологии), поэтому он служит внешней проверкой, а не признаком (п. 1.5, 8.6). Сети по потокам людей нет: в выгрузке нет пар «откуда — куда».
- 24 месяца: сезонность видна, длинного тренда нет.
- Траты — модельная оценка по безналичным операциям; уровень смешивает доход и долю безнала.
- Росстат без малого предпринимательства; население за 2024 год нет по Рязанской области, за 2023-й — по Кемеровской.

- 174 МО с неполными рядами в типологию не вошли.
- Косинусный граф и признаки построены из одних долей (п. 3.2, пункт 5).
- В первом прогоне KEFRiN и CANUS $K = 8$ задано вручную, веса ρ , ξ , ζ равны 1 без подбора.
- Паттерны полного порядка слишком дробны (127) и неустойчивы по месяцам; порог равенства $\varepsilon = 0,05$ увеличивает их число до 1 235.
- Тип МО в разделе 8 — модальный за 24 месяца; смены типа в нём не видны (их разбирает раздел 7).
- Типы 5 и 6 неустойчивы в бутстрэпе (Жаккар 0,56 и 0,59) и дают почти все помесечные события MONIC (п. 7.5–7.6). Бутстрэп по месяцам — 4 месяца из 24 по 10 прогонов, это грубая оценка.
- Номера типов между месяцами согласованы задним числом: сначала венгерским алгоритмом, затем под модальный тип МО (п. 7.1).
- Шкала FCA по квартилям не разделяет два городских типа 3 и 5 (п. 8.5); числовые узорные структуры [30] — следующий шаг.
- Росстат без малого предпринимательства не видит общепит и часть торговли; доли занятых по разделам скрыты у многих МО (п. 8.6).
- Прочтение AVU зависит от формулы, которую мы взяли из открытого кода лаборатории, а не из закрытого первоисточника (п. 5.4). Что MQ — это модулярность, подтвердили организаторы (п. 5.5).

Что дальше.

- Если индекс мобильности появится по всей стране, добавить его атрибутом МО. Для слоя сети нужны потоки между МО, в открытой выгрузке их нет.
- Согласованное разбиение сразу по всем месяцам — многослойная модулярность [27] — вместо сопоставления меток задним числом.
- SEFNAC Шалилеха и Миркина [14] как независимый арбитр числа кластеров: он выделяет кластеры по одному и сам решает, когда остановиться.
- Слияние мелких паттернов по R^2 и сглаживание за три месяца.
- Отнести 174 МО с неполными рядами к ближайшему типу по тем месяцам, которые у них есть.

Литература

1. Rousseeuw P.J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis // Journal of Computational and Applied Mathematics. 1987. Vol. 20. P. 53–65. doi:10.1016/0377-0427(87)90125-7
2. Caliński T., Harabasz J. A dendrite method for cluster analysis // Communications in Statistics. 1974. Vol. 3, № 1. P. 1–27. doi:10.1080/03610927408827101
3. Halkidi M., Vazirgiannis M. Clustering validity assessment: finding the optimal partitioning of a data set // Proc. IEEE ICDM 2001. P. 187–194. doi:10.1109/ICDM.2001.989517
4. Biswas A., Biswas B. Defining quality metrics for graph clustering evaluation // Expert Systems with Applications. 2017. Vol. 71. P. 1–17. doi:10.1016/j.eswa.2016.11.011
5. Newman M.E.J., Girvan M. Finding and evaluating community structure in networks // Physical Review E. 2004. Vol. 69. 026113. doi:10.1103/PhysRevE.69.026113
6. Mitchell B.S., Mancoridis S. On the automatic modularization of software systems using the Bunch tool // IEEE Transactions on Software Engineering. 2006. Vol. 32, № 3. P. 193–208. doi:10.1109/TSE.2006.31
7. Lloyd S. Least squares quantization in PCM // IEEE Transactions on Information Theory. 1982. Vol. 28, № 2. P. 129–137. doi:10.1109/TIT.1982.1056489
8. Arthur D., Vassilvitskii S. k-means++: the advantages of careful seeding // Proc. SODA 2007. P. 1027–1035.
9. Traag V.A., Waltman L., van Eck N.J. From Louvain to Leiden: guaranteeing well-connected communities // Scientific Reports. 2019. Vol. 9. 5233. doi:10.1038/s41598-019-41695-z
10. Reichardt J., Bornholdt S. Statistical mechanics of community detection // Physical Review E. 2006. Vol. 74. 016110. doi:10.1103/PhysRevE.74.016110
11. Shalileh S., Mirkin B. Community partitioning over feature-rich networks using an extended k-means method // Entropy. 2022. Vol. 24, № 5. 626. doi:10.3390/e24050626. Код: github.com/Sorooshi/KEFRiN
12. Shalileh S. CANUS // IEEE Access. 2025. doi:10.1109/ACCESS.2025.3614989. Код: github.com/Sorooshi/CANUS
13. Mirkin B. Clustering: A Data Recovery Approach. 2nd ed. Boca Raton: CRC Press, 2012.
14. Shalileh S., Mirkin B. [SEFNAC] // Journal of Classification. 2022. Vol. 39, № 3. doi:10.1007/s00357-022-09416-w
15. Shalileh S., Antonov E., Tsyplakova D. Internal cluster validity indices for attributed networks: a controlled comparative study // Expert Systems with Applications. 2026. 133912. doi:10.1016/j.eswa.2026.133912
16. Shalileh S., Antonov E., Tsyplakova D. Profiling consumption using attributed network clustering // Complex Networks & Their Applications XIV. Springer, 2026. P. 77–88. doi:10.1007/978-3-032-16723-1_7

17. Алескеров Ф.Т., Белоусова В.Ю., Егорова Л.Г., Миркин Б.Г. Анализ паттернов в статике и динамике. Ч. 1 // Бизнес-информатика. 2013. № 3 (25). С. 3–18; Ч. 2 // Бизнес-информатика. 2013. № 4 (26). С. 3–20.
18. Myachin A.L. Pattern analysis in parallel coordinates based on pairwise comparison of parameters // Automation and Remote Control. 2019. Vol. 80, № 1. P. 112–123. doi:10.1134/S0005117919010107
19. Aleskerov F., Yakuba V., Yuzbashev D. A 'threshold aggregation' of three-graded rankings // Mathematical Social Sciences. 2007. Vol. 53, № 1. P. 106–110. doi:10.1016/j.mathsocsci.2006.09.002
20. de Borda J.-C. Mémoire sur les élections au scrutin // Histoire de l'Académie Royale des Sciences. Paris, 1781.
21. Kuhn H.W. The Hungarian method for the assignment problem // Naval Research Logistics Quarterly. 1955. Vol. 2. P. 83–97. doi:10.1002/nav.3800020109
22. Vinh N.X., Epps J., Bailey J. Information theoretic measures for clusterings comparison: variants, properties, normalization and correction for chance // Journal of Machine Learning Research. 2010. Vol. 11. P. 2837–2854.
23. Spiliopoulou M., Ntoutsi I., Theodoridis Y., Schult R. MONIC: modeling and monitoring cluster transitions // Proc. KDD 2006. P. 706–711. doi:10.1145/1150402.1150491
24. Hennig C. Cluster-wise assessment of cluster stability // Computational Statistics & Data Analysis. 2007. Vol. 52, № 1. P. 258–271. doi:10.1016/j.csda.2006.11.025
25. Ganter B., Wille R. Formal Concept Analysis: Mathematical Foundations. Berlin: Springer, 1999.
26. Kuznetsov S.O. On stability of a formal concept // Annals of Mathematics and Artificial Intelligence. 2007. Vol. 49. P. 101–115. doi:10.1007/s10472-007-9053-6
27. Mucha P.J., Richardson T., Macon K., Porter M.A., Onnela J.-P. Community structure in time-dependent, multiscale, and multiplex networks // Science. 2010. Vol. 328, № 5980. P. 876–878. doi:10.1126/science.1184819
28. Sakoe H., Chiba S. Dynamic programming algorithm optimization for spoken word recognition // IEEE Transactions on Acoustics, Speech, and Signal Processing. 1978. Vol. 26, № 1. P. 43–49. doi:10.1109/TASSP.1978.1163055
29. Buzmakov A., Kuznetsov S.O., Napoli A. Scalable estimates of concept stability // Proc. ICFA 2014. LNCS 8478. P. 157–172. doi:10.1007/978-3-319-07248-7_12
30. Kaytoue M., Kuznetsov S.O., Napoli A., Duplessis S. Mining gene expression data with pattern structures in formal concept analysis // Information Sciences. 2011. Vol. 181, № 10. P. 1989–2001. doi:10.1016/j.ins.2010.07.007
31. Tomczak M., Tomczak E. The need to report effect size estimates revisited. An overview of some recommended measures of effect size // Trends in Sport Sciences. 2014. Vol. 1, № 21. P. 19–25.
32. Ward J.H. Hierarchical grouping to optimize an objective function // Journal of the American Statistical Association. 1963. Vol. 58, № 301. P. 236–244. doi:10.1080/01621459.1963.10500845
33. Dempster A.P., Laird N.M., Rubin D.B. Maximum likelihood from incomplete data via the EM algorithm // Journal of the Royal Statistical Society. Series B. 1977. Vol. 39, № 1. P. 1–38. doi:10.1111/j.2517-6161.1977.tb01600.x
34. Shi J., Malik J. Normalized cuts and image segmentation // IEEE Transactions on Pattern Analysis and Machine Intelligence. 2000. Vol. 22, № 8. P. 888–905. doi:10.1109/34.868688
35. von Luxburg U. A tutorial on spectral clustering // Statistics and Computing. 2007. Vol. 17, № 4. P. 395–416. doi:10.1007/s11222-007-9033-z

Данные. СберИндекс: набор данных хакатона (безналичные расходы по МО, индекс доступности рынков, связи МО), CC BY-SA 4.0; справочник муниципальных образований и их границ, CC BY-SA 4.0; индекс мобильности (API sberindex.ru, 30.09.2026). Росстат: база данных показателей муниципальных образований (БДМО), выгрузка каталога «Если быть точным», CC BY 4.0.